Lucas de Oliveira Freitas

Investigação de Determinantes do Ibovespa através de Aprendizado de Máquina Interpretável e Inferência Causal

São José dos Campos, SP

Lucas de Oliveira Freitas

Investigação de Determinantes do Ibovespa através de Aprendizado de Máquina Interpretável e Inferência Causal

Trabalho de conclusão de curso apresentado ao Instituto de Ciência e Tecnologia – UNIFESP, como parte das atividades para obtenção do título de Bacharel em Ciência da Computação.

Universidade Federal de São Paulo – UNIFESP

Instituto de Ciência de Tecnologia

Bacharelado em Ciência da Computação

Orientador: Prof. Dr. Renato Cesar Sato

São José dos Campos, SP

Julho de 2026

Agradecimentos

Agradeço, em primeiro lugar, à minha família, pelo apoio constante e pela base sólida que sempre me proporcionaram. Sem o incentivo e a confiança de vocês, essa caminhada teria sido muito mais difícil. Obrigado por acreditarem em mim em todos os momentos, mesmo nos mais desafiadores.

Aos meus amigos, que estiveram presentes ao longo da jornada universitária — nos estudos, nas conversas, nos momentos de descanso e nas celebrações —, minha sincera gratidão. A convivência, a troca de ideias e o apoio mútuo fizeram toda a diferença para que esse percurso fosse mais leve, humano e enriquecedor.

Aos professores e orientadores que cruzaram meu caminho durante a graduação, deixo um agradecimento especial. Cada aula, orientação e conselho foram fundamentais para minha formação crítica, técnica e ética.

Por fim, agradeço à universidade, pelo espaço de aprendizado, pesquisa e crescimento que me proporcionou. Levo comigo não apenas o conhecimento adquirido, mas também os valores e experiências que moldaram quem sou hoje.

“Não busque que as coisas aconteçam como você deseja,
mas sim que você queira as coisas como elas acontecem."
(Epicteto)

Resumo

Este trabalho investiga os fatores macroeconômicos que explicam o comportamento de variáveis financeiras no Brasil, por meio de modelos estatísticos e de aprendizado de máquina interpretável, com ênfase no balanço entre precisão preditiva e transparência explicativa. A metodologia envolveu a construção de uma base de dados diária com séries temporais da taxa Selic, câmbio, IPCA, PIB, Ibovespa e risco-país (EMBI+), transformadas por retornos logarítmicos e primeiras diferenças e validadas por testes de estacionariedade (ADF e KPSS). Foram estimados cinco modelos em sequência: ARIMA e MQO como linha de base, seguidos por um Generalized Additive Model (GAM), um modelo Bayesian Structural Time Series (BSTS) e um Causal Forest. O MQO apresentou R^2 de 0,209 *in-sample*, identificando impacto negativo e significativo do câmbio e do risco-país. O GAM obteve R^2 de 0,2946 no treino e 0,3045 no conjunto de teste (2020–2024), melhor desempenho preditivo entre os modelos, capturando não linearidades sem sobreajuste e com otimização via *holdout* interno 2018–2019. O BSTS, estimado pelo estimador MAP da biblioteca `orbit-ml`, decompôs a série em componentes estruturais (tendência, sazonalidade e regressão), realizou seleção probabilística de variáveis e atingiu MAE de 0,010147 e R^2 de 0,2436 no teste, com a reincorporação do EMBI+ por *prior* heterogêneo como principal fator de melhora. O Causal Forest, estimado pelo `CausalForestDML` com busca aleatória de hiperparâmetros guiada por R-loss causal e vetor expandido para oito covariáveis (incluindo VIX, S&P 500 e petróleo Brent como variáveis de risco global), revelou que o efeito causal médio de um choque cambial sobre o Ibovespa não é estatisticamente distinto de zero (ATE $= +0{,}000075$, IC 95% cruzando zero), mas a heterogeneidade do efeito condicional foi confirmada pelo Best Linear Predictor ($\beta_1 = 51{,}70$, $p < 0{,}001$), com o risco-país (ΔEMBI+) respondendo por 32,6% da modulação e as variáveis globais somadas por 28,4%. Nesse modelo, a métrica de maior relevância é o efeito condicional de tratamento (CATE), de natureza causal; a reconstrução preditiva associada atingiu R^2 de 0,40 no conjunto de teste, valor reportado apenas como métrica secundária e não diretamente comparável à dos demais modelos, por apoiar-se em três covariáveis globais ausentes dos outros e no tratamento observado. Destaca-se, como resultado central do trabalho, a convergência independente dos três modelos interpretáveis — matematicamente distintos entre si — para o mesmo determinante dominante: o risco-país (ΔEMBI+) e o câmbio emergem como os principais canais de transmissão macroeconômica sobre o Ibovespa nos três arcabouços, resultado que nenhum método isolado poderia confirmar com igual robustez. Conclui-se que a aplicação de modelos explicativos com IA interpretável representa uma abordagem promissora e complementar para compreender a dinâmica dos mercados financeiros brasileiros, com cada modelo contribuindo com uma perspectiva distinta: flexibilidade não linear (GAM), estrutura temporal probabilística (BSTS) e heterogeneidade causal com dimensão global (Causal Forest).

Palavras-chaves: modelos explicativos; aprendizado de máquina interpretável; macroeconomia; séries temporais; inteligência artificial aplicada.

Abstract

This study investigates the macroeconomic factors that explain the behavior of financial variables in Brazil using statistical models and interpretable machine learning techniques, with emphasis on balancing predictive accuracy and explanatory transparency. The methodology involved the construction of a daily time series dataset including the Selic interest rate, exchange rate, IPCA inflation, GDP, Ibovespa, and country risk (EMBI+), transformed via logarithmic returns and first differences and validated through stationarity tests (ADF and KPSS). Five models were estimated in sequence: ARIMA and OLS as benchmarks, followed by a Generalized Additive Model (GAM), a Bayesian Structural Time Series (BSTS) model, and a Causal Forest. The OLS model yielded an R^2 of 0.209 *in-sample*, identifying a significant negative effect of the exchange rate and country risk on Ibovespa returns. The GAM achieved an R^2 of 0.2946 on the training set and 0.3045 on the test set (2020–2024), the best predictive performance among all models, capturing nonlinearities without overfitting through optimization via an internal holdout (2018–2019). The BSTS, estimated using the MAP estimator from the `orbit-ml` library, decomposed the series into structural components (trend, seasonality, and regression), performed probabilistic variable selection, and achieved an MAE of 0.010147 and an R^2 of 0.2436 on the test set, with the reincorporation of EMBI+ via heterogeneous prior as the main driver of improvement. The Causal Forest, estimated using `CausalForestDML` with random search guided by causal R-loss and an expanded covariate vector of eight variables (including VIX, S&P 500, and Brent crude oil as global risk variables), revealed that the average causal effect of an exchange rate shock on the Ibovespa is not statistically distinguishable from zero (ATE $= +0.000075$, 95% CI crossing zero), while the heterogeneity of the conditional effect was confirmed by the Best Linear Predictor ($\beta_1 = 51.70$, $p < 0.001$), with country risk (ΔEMBI+) accounting for 32.6% of the modulation and the combined global variables for 28.4%. For this model, the most relevant metric is the conditional average treatment effect (CATE), which is causal in nature; the associated predictive reconstruction achieved an R^2 of 0.40 on the test set, reported only as a secondary metric that is not directly comparable to the other models, as it relies on three global covariates absent from the others and on the observed treatment. A key result is the independent convergence of three mathematically distinct interpretable models — GAM, BSTS, and Causal Forest — toward the same dominant determinant: country risk (ΔEMBI+) and the exchange rate emerge as the main macroeconomic transmission channels for the Ibovespa across all three frameworks, a methodological triangulation that no single method could confirm with equal robustness. The findings suggest that interpretable AI-based explanatory models offer a promising and complementary approach to understanding Brazilian financial market dynamics, with each model contributing a distinct perspective: nonlinear flexibility (GAM), probabilistic temporal structure (BSTS), and causal heterogeneity with global dimension (Causal Forest).

Key-words: explanatory models; interpretable machine learning; macroeconomics; time series; applied artificial intelligence.

Lista de ilustrações

Figura 1 – Mapa de Calor - Correlação das Variáveis Transformadas (Fonte: Autor) . . 46
Figura 2 – Gráficos ACF e PACF da série transformada (Fonte: Autor) 46
Figura 3 – Partial Dependence Plots (PDPs) do GAM final (G4+G8): efeito marginal das sete variáveis preditoras sobre o retorno logarítmico do Ibovespa, incluindo IPCA em primeiras diferenças e *feature* autorregressiva `ibov_lag1` (Fonte: Autor) 50
Figura 4 – Distribuições posteriores dos coeficientes do BSTS completo. Variáveis cujo IC 90% não cruza zero (azul) são selecionadas; a variável removida (salmão) corresponde ao ΔEMBI+ (Fonte: Autor) 52
Figura 5 – Curva de MAE e RMSE no *holdout* 2018–2019 em função de `sigma_prior` (escala logarítmica). O mínimo ocorre em $\sigma^* = 0{,}01$ (Fonte: Autor) 53
Figura 6 – Previsão pontual BSTS *out-of-sample* (2020–2024) com estimador MAP (Fonte: Autor) 54
Figura 7 – Decomposição estrutural BSTS: tendência, sazonalidade e regressão sobre o período de teste (Fonte: Autor) 54
Figura 8 – Distribuição do CATE estimado pelo Causal Forest no conjunto de teste (2020–2024). A linha vertical indica o ATE $= +0{,}000075$, cujo intervalo de confiança de 95% cruza zero. A dispersão de $\tau(x)$ ao redor do ATE nulo evidencia a heterogeneidade do efeito causal condicional (Fonte: Autor) . . 57
Figura 9 – GATES por decil do CATE estimado: efeito médio de tratamento em cada grupo, com intervalos de confiança de 95%. Os GATES exibem monotonicidade estritamente crescente, de $-0{,}002581$ (decil 1) a $+0{,}002867$ (decil 10). Nenhum decil individualmente apresenta IC inteiramente fora de zero, resultado consistente com o tamanho amostral do período de teste; a heterogeneidade é detectável globalmente pelo BLP ($\beta_1 = 51{,}70$, $p < 0{,}001$) (Fonte: Autor) 58
Figura 10 – Importância das covariáveis na heterogeneidade do CATE, calculada pelo critério nativo do `CausalForestDML`. Com oito covariáveis, o ΔEMBI+ (risco-país) responde por 32,6% da variação do efeito condicional, seguido do PIB (20,1%), IPCA (19,0%) e das três variáveis globais somadas (28,4%: petróleo 10,1%, S&P 9,3%, VIX 9,0%) (Fonte: Autor) 59
Figura 11 – PDPs do CATE estimado em função de cada covariável: efeito marginal da variável sobre a heterogeneidade do efeito causal do choque cambial. A curva do ΔEMBI+ exibe relação negativa, com o efeito do choque tornando-se mais negativo à medida que o risco soberano aumenta (Fonte: Autor) . . 60

Figura 12 – Valores SHAP para o CATE estimado (LUNDBERG; ALLEN; LEE, 2017): cada ponto representa uma observação do conjunto de teste, e a posição horizontal indica a contribuição da covariável para o afastamento de $\hat{\tau}(x)$ em relação ao ATE. O ΔEMBI+ domina, com valores SHAP elevados em dias de alto risco-país associados a efeitos causais mais negativos (Fonte: Autor) 61

Lista de tabelas

Tabela 1 – Estatísticas descritivas das séries brutas antes das transformações de estacionariedade. Selic: valor diário da taxa anual; câmbio: R$/US$ (dólar comercial); IPCA: variação mensal (%); PIB: R$ milhões correntes (trimestral, interpolado); Ibovespa: pontos; EMBI+: pontos-base; expectativa IPCA: % ao mês (Fonte: Autor). 31

Tabela 2 – Transformações aplicadas às variáveis da base de dados 45

Tabela 3 – Fatores de Inflação da Variância (VIF) para as variáveis explicativas do MQO 47

Tabela 4 – Métricas de avaliação dos modelos estimados — linha de base *in-sample* (conjunto completo) 48

Tabela 5 – Busca pelo número ótimo de splines no GAM: R^2 no subconjunto de ajuste (2001–2017) e MAE no *holdout* 2018–2019 (negrito = configuração selecionada) 48

Tabela 6 – Análise *smooth* vs. linear por variável com critério no *holdout* 2018–2019: $\Delta\text{MAE}_j > 0$ indica ganho não linear 48

Tabela 7 – Estatísticas posteriores dos coeficientes do BSTS completo: média, desvio padrão e intervalo de credibilidade a 90%. A variável é selecionada quando o IC 90% não cruza zero. 51

Tabela 8 – Busca em grade para `sigma_prior`: MAE e RMSE no *holdout* 2018–2019 (negrito = configuração selecionada). 53

Tabela 9 – Comparativo de desempenho entre os três limiares de choque cambial ($p70$, $p75$, $p80$). Em todos os casos, o ATE não é estatisticamente distinto de zero e a heterogeneidade permanece detectável. O limiar $p75$ (negrito) foi adotado como configuração principal por combinar o melhor R^2 preditivo com a justificativa convencional na literatura de volatilidade cambial. 61

Tabela 10 – Comparativo completo de métricas: linha de base *in-sample* (conjunto completo) e avaliação *out-of-sample* (teste: jan/2020–jul/2024). O melhor desempenho preditivo fora da amostra está destacado em negrito. As métricas do Causal Forest referem-se à reconstrução $\hat{Y} = \hat{m}_0(X) + \hat{\tau}(X) \cdot T$, cujo objetivo primário é causal, não preditivo. 63

Lista de abreviaturas e siglas

ADF	Augmented Dickey-Fuller (Teste de Dickey-Fuller Aumentado)
AIC	Akaike Information Criterion (Critério de Informação de Akaike)
AR	AutoRegressive (Componente autorregressivo)
ARIMA	AutoRegressive Integrated Moving Average (Modelo autorregressivo integrado de médias móveis)
BSTS	Bayesian Structural Time Series (Modelo Bayesiano de Séries Temporais Estruturais)
CAPM	Capital Asset Pricing Model (Modelo de Precificação de Ativos de Capital)
CATE	Conditional Average Treatment Effect (Efeito Médio Condicional de Tratamento)
EMBI+	Emerging Markets Bond Index Plus (Índice de Risco-País)
GAM	Generalized Additive Model (Modelo Aditivo Generalizado)
IA	Inteligência Artificial
IBGE	Instituto Brasileiro de Geografia e Estatística
IBOV	Índice Bovespa (principal índice da B3)
KPSS	Kwiatkowski–Phillips–Schmidt–Shin (Teste de estacionariedade)
MA	Moving Average (Componente de médias móveis)
MAE	Mean Absolute Error (Erro Médio Absoluto)
MCMC	Markov Chain Monte Carlo (Cadeias de Markov via Monte Carlo)
MQO	Mínimos Quadrados Ordinários
PIB	Produto Interno Bruto
R^2	Coeficiente de Determinação (medida de ajuste do modelo)
RMSE	Root Mean Squared Error (Raiz do Erro Quadrático Médio)
SHAP	SHapley Additive exPlanations (Explicações Aditivas de Shapley)
VIF	Variance Inflation Factor (Fator de Inflação da Variância)

Sumário

1 Introdução 12
1.1 Objetivos 13

2 Fundamentação Teórica 15
2.1 Variáveis Macroeconômicas Relevantes 15
2.2 Modelos de Equilíbrio Macroeconômico 16
2.2.1 IS-LM 16
2.2.2 Hipótese das expectativas racionais 17
2.3 Modelos de Precificação de Ativos 17
2.3.1 Capital Asset Pricing Model (CAPM) 17
2.3.2 Arbitrage Pricing Theory (APT) 18
2.4 Teoria dos Mercados Eficientes e Choques Macroeconômicos 19

3 Modelagem Estatística e Econométrica 21
3.1 Séries Temporais e Estacionaridade 21
3.2 Modelos ARIMA 22
3.3 Regressão Linear Múltipla por MQO 23
3.4 Limitações e justificativa para modelos avançados 24

4 Modelos Explicativos com IA Interpretável 25
4.1 Generalized Additive Models (GAM) 26
4.2 Bayesian Structural Time Series (BSTS) 27
4.3 Causal Forests 27

5 Metodologia 30
5.1 Coleta e Tratamento de Dados 30
5.2 Análise Exploratória e Testes de Estacionariedade 31
5.2.1 Análise de Correlação 31
5.2.2 Testes de Estacionariedade 32
5.3 Modelagem Econométrica Tradicional 33
5.4 Análise Exploratória Direcionada 33
5.4.1 Escala, Esparsidade e Correlação com o Alvo 33
5.4.2 Autocorrelação do Alvo e Defasagem dos Regressores 34
5.4.3 Implicações Metodológicas 34
5.5 Avaliação Out-of-Sample e Validação Temporal 34
5.6 Otimização e Configuração do Modelo GAM 36

5.6.1 Seleção do número de splines (*n_splines*) . . . 36
5.6.2 Seleção do tipo de termo por variável (*smooth* vs. linear) . . . 37
5.6.3 Ajustes Adicionais: Transformação do IPCA e Variável Autorregressiva 37
5.7 Configuração e Estimação do Modelo BSTS . . . 37
5.7.1 Seleção de Variáveis via Intervalos de Credibilidade . . . 38
5.7.2 Otimização do hiperparâmetro *sigma_prior* . . . 38
5.7.3 Ajuste Final e Decomposição Estrutural . . . 38
5.8 Configuração e Otimização do Modelo Causal Forest . . . 39
5.8.1 Hipóteses de Identificação Causal . . . 41

6 Revisão Bibliográfica . . . 43

7 Resultados Parciais . . . 45
7.1 Linha de Base . . . 45
7.2 Resultados do Modelo GAM . . . 48
7.3 Resultados do Modelo BSTS . . . 51
7.3.1 Seleção Bayesiana de Variáveis . . . 51
7.3.2 Otimização do Encolhimento Bayesiano . . . 52
7.3.3 Avaliação Out-of-Sample e Decomposição Estrutural . . . 53
7.3.4 Discussão Comparativa: GAM e BSTS . . . 55
7.4 Resultados do Modelo Causal Forest . . . 56
7.4.1 Efeito Causal Médio e Distribuição do CATE . . . 56
7.4.2 Calibração do CATE pelo Best Linear Predictor . . . 57
7.4.3 Heterogeneidade por Grupo: GATES . . . 58
7.4.4 Covariáveis que Modulam o Efeito: Importância e PDPs . . . 59
7.4.5 Robustez da Escolha do Limiar . . . 61
7.4.6 Reconstrução Preditiva e Posicionamento Comparativo . . . 62
7.5 Síntese Comparativa dos Modelos . . . 62

8 Conclusão . . . 65

Referências . . . 69

1 Introdução

Nos últimos anos, economistas financeiros e formuladores de políticas públicas têm demonstrado crescente interesse na aplicação de modelos de aprendizado de máquina para resolver problemas clássicos em finanças. Isso se deve, em parte, à capacidade desses modelos de identificar variáveis potencialmente relevantes e capturar relações complexas entre os preditores e variáveis-alvo. Entretanto, a maioria dos modelos de machine learning são frequentemente tratados como caixas-pretas (black boxes), dificultando a interpretação de seus resultados de forma acessível a economistas, gestores e investidores (BRIGO et al., 2021).

Diante disso, a interpretabilidade dos modelos não é um mero diferencial técnico, mas uma exigência ética e regulatória incontornável — especialmente quando os resultados embasam decisões de alto risco no mercado financeiro. RUDIN (2019) defende de forma contundente que, para domínios de alto impacto, deveríamos parar de tentar explicar modelos opacos e, em vez disso, construir modelos inerentemente interpretáveis desde o início. A autora demonstra que o suposto trade-off entre acurácia e interpretabilidade é, em grande parte, um mito: modelos transparentes e bem construídos frequentemente igualam ou superam seus equivalentes opacos, sem impor o custo da opacidade. Este trabalho adota essa postura diretamente ao atacar o problema da caixa-preta em sua raiz — não por meio de explicações post hoc aplicadas sobre modelos opacos, mas pela adoção de arquiteturas inerentemente transparentes. Em setores regulados como o financeiro, onde decisões de precificação de risco, alocação de capital e gestão de portfólios devem ser auditáveis e justificáveis perante reguladores e investidores, essa escolha transcende o técnico e se torna ética.

No contexto das finanças brasileiras, essa necessidade se intensifica. Instituições financeiras e órgãos reguladores demandam modelos robustos, mas também explicáveis, para embasar decisões estratégicas e políticas econômicas. Um exemplo crítico é a estimativa de taxas de recuperação de crédito em eventos de inadimplência, um parâmetro-chave segundo os acordos de Basileia II e III (NAZEMI; FABOZZI, 2024). A adoção de abordagens baseadas em Inteligência Artificial (IA) para estimar tais indicadores tem ganhado tração, superando frequentemente métodos estatísticos tradicionais. Ainda assim, muitos desses avanços se restringem a modelos preditivos com pouca ou nenhuma transparência sobre as relações causais envolvidas.

A relevância científica dessa discussão assume contornos ainda mais críticos em economias emergentes como o Brasil. Ao contrário de mercados desenvolvidos, o ambiente financeiro brasileiro é marcado por dinâmicas próprias de risco — incluindo alta sensibilidade ao câmbio, volatilidade associada ao risco-país (EMBI+) e reações não lineares a choques políticos e econômicos. Nesse contexto, modelos opacos que funcionam bem em mercados estáveis podem falhar de formas silenciosas e graves quando submetidos a essas particularidades estruturais. A

interpretabilidade torna-se, portanto, não apenas um requisito de transparência, mas uma ferramenta indispensável para identificar essas falhas, compreender por que o modelo se comporta de determinada maneira sob estresse cambial ou aumento abrupto do risco-país, e validar se os mecanismos capturados são economicamente coerentes com a teoria.

A essas considerações soma-se um arcabouço normativo brasileiro que, nos últimos anos, deslocou a explicabilidade da condição de preferência metodológica para a de exigência legal e prudencial. A Lei Geral de Proteção de Dados (LGPD), em seu Art. 20, assegura ao titular o direito de revisão de decisões automatizadas que afetem seus interesses, incluindo expressamente as decisões de crédito, e impõe ao controlador o dever de fornecer informações claras sobre os critérios utilizados nessas decisões (Brasil, 2018). No plano prudencial, as Resoluções do Conselho Monetário Nacional nº 4.557/2017 e nº 4.966/2021 exigem que modelos quantitativos de risco utilizados por instituições financeiras sejam auditáveis, documentados e submetidos a avaliação periódica de adequação e robustez (Banco Central do Brasil, 2017; Banco Central do Brasil, 2021), sendo que a segunda, em vigor desde 2025, introduziu o regime de perdas esperadas em consonância com o IFRS 9 e ampliou a demanda regulatória por modelos preditivos verificáveis. A Autoridade Nacional de Proteção de Dados (ANPD), por sua vez, encerrou em janeiro de 2025 a Tomada de Subsídios voltada à regulamentação do tratamento automatizado de dados pessoais, sinalizando que o regime de explicabilidade exigível continuará a se consolidar nos próximos anos (Autoridade Nacional de Proteção de Dados (ANPD), 2025). Em conjunto, esses normativos tornam a interpretabilidade uma condição de conformidade jurídica e prudencial, e não apenas um atributo desejável dos modelos.

Este trabalho contribui para essa literatura ao propor e testar modelos explicativos de aprendizado de máquina aplicados à análise de variáveis macroeconômicas e financeiras no Brasil. O objetivo é compreender os fatores que determinam, por exemplo, o comportamento de índices como o Ibovespa e a taxa de câmbio, explorando estruturas causais e padrões latentes de forma interpretável. Modelos como Generalized Additive Models (GAM), Bayesian Structural Time Series (BSTS) e Causal Forests foram utilizados, acompanhados de técnicas de explicação como SHAP (SHapley Additive exPlanations) e PDP (Partial Dependence Plots), permitindo que os resultados sejam interpretados à luz da teoria econômica clássica e moderna.

Ao integrar inteligência artificial com fundamentos econômicos, este trabalho buscou não apenas construir modelos mais precisos e úteis para a análise financeira, mas também garantir que seus resultados pudessem ser auditados, discutidos e compreendidos à luz da teoria econômica.

1.1 Objetivos

O objetivo central deste trabalho é compreender os fatores que determinam o comportamento de variáveis financeiras e macroeconômicas brasileiras — em particular os retornos

do Ibovespa e a taxa de câmbio —, explorando estruturas causais e padrões latentes de forma interpretável, de modo que os resultados obtidos possam ser auditados e avaliados quanto à sua coerência econômica. Diferentemente de abordagens puramente preditivas, que se contentam com a minimização do erro de previsão, a orientação adotada aqui exige que cada modelo seja capaz de revelar os mecanismos subjacentes ao fenômeno estudado, permitindo que economistas, gestores e reguladores compreendam por quais razões determinada variável exerce influência sobre o mercado e em que condições essa influência se modifica.

Para alcançar esse objetivo, o trabalho se organiza em torno de cinco metas específicas articuladas entre si. Em primeiro lugar, modelos econométricos clássicos — ARIMA e Mínimos Quadrados Ordinários (MQO) — foram estimados como linha de base interpretável de referência, estabelecendo um patamar de comparação fundamentado na teoria estatística e econométrica tradicional e fornecendo métricas iniciais de desempenho fora da amostra. Complementarmente, um Modelo Aditivo Generalizado (GAM) foi aplicado com o propósito de capturar relações não lineares entre as variáveis macroeconômicas e os retornos do Ibovespa, preservando a interpretabilidade por meio de funções suaves por variável que podem ser inspecionadas individualmente. Avançando na dimensão temporal, o modelo de Séries Temporais Estruturais Bayesianas (BSTS) foi empregado para incorporar decomposição estrutural da série e inferência bayesiana sobre os coeficientes de regressão, conferindo ao modelo capacidade de separar tendências, sazonalidade e efeitos de preditores de forma probabilística e auditável. Adicionalmente, o Causal Forest foi utilizado para estimar o efeito causal heterogêneo de choques cambiais sobre os retornos do Ibovespa, levando em conta o contexto macroeconômico de cada observação e identificando em quais condições o impacto desses choques se amplifica ou se atenua. Por fim, os quatro modelos foram comparados sistematicamente em termos de capacidade explicativa, desempenho preditivo fora da amostra e interpretabilidade econômica, avaliando em que medida suas contribuições são complementares e de que forma cada arquitetura ilumina aspectos distintos da dinâmica financeira brasileira.

2 Fundamentação Teórica

2.1 Variáveis Macroeconômicas Relevantes

A compreensão do comportamento dos mercados financeiros exige a análise de um conjunto de variáveis macroeconômicas fundamentais que refletem o estado da economia e influenciam diretamente a percepção de risco, o custo do capital e o fluxo de investimentos. Entre essas variáveis, destacam-se o Produto Interno Bruto (PIB), a inflação, a taxa Selic (Sistema Especial de Liquidação e de Custódia), o câmbio e o risco-país. Essas grandezas são amplamente monitoradas por analistas, formuladores de política econômica e agentes do mercado, e representam componentes essenciais nos modelos explicativos que buscam compreender a dinâmica dos ativos financeiros.

O Produto Interno Bruto (PIB) é a medida agregada mais abrangente da atividade econômica de um país, refletindo o valor total dos bens e serviços finais produzidos em um determinado período. No contexto financeiro, o PIB serve como indicador da saúde econômica geral, influenciando expectativas sobre lucros corporativos, demanda agregada e política monetária. A variação do PIB está frequentemente associada ao desempenho de índices acionários e à atratividade do país para investimentos externos.

A inflação, geralmente medida pelo Índice de Preços ao Consumidor Amplo (IPCA) no Brasil, indica o ritmo de crescimento dos preços na economia (CARRARA; CORREA, 2012). Taxas inflacionárias elevadas reduzem o poder de compra da moeda e podem corroer o retorno real dos investimentos. Além disso, a inflação influencia diretamente as decisões do Banco Central em relação à política monetária, tornando-se um determinante indireto da taxa de juros e, por consequência, dos preços dos ativos financeiros (BRASIL, 2025).

A taxa Selic, principal instrumento de política monetária, representa o custo básico do crédito na economia. Mudanças na Selic afetam o custo de oportunidade do capital, impactando o valuation dos ativos, a taxa de câmbio e o comportamento dos investidores. A elevação da Selic tende a atrair capital estrangeiro de curto prazo, valorizando a moeda local, enquanto sua redução estimula o consumo e o investimento doméstico, podendo pressionar a inflação e instigando o volume de crédito direcionado para economia brasileira (PONTEL; TRISTÃO; BOLIGON, 2020).

O câmbio, frequentemente representado pela taxa de conversão do real frente ao dólar americano, exerce influência direta sobre a competitividade das exportações, a rentabilidade de empresas com exposição internacional e o comportamento dos fluxos de capital. Em mercados emergentes como o Brasil, o câmbio é também um termômetro de percepção de risco e pode reagir de forma sensível a choques internos ou externos (NUNES; COMPAGNORE; SALES,

2020).

Por fim, o risco-país, comumente mensurado pelo indicador EMBI+ (Emerging Markets Bond Index), reflete a confiança dos investidores internacionais na capacidade de um país honrar seus compromissos financeiros (RODRíGUEZ, 2016). O aumento do risco-país eleva o prêmio de risco exigido pelos investidores, encarece o financiamento externo e pressiona o câmbio e os ativos domésticos. É, portanto, uma variável crítica na análise do comportamento dos mercados em economias sujeitas a volatilidade macroeconômica.

A escolha dessas variáveis para compor os modelos explicativos fundamenta-se tanto em sua relevância teórica quanto na evidência empírica consolidada na literatura econômica e financeira. Juntas, elas capturam aspectos estruturais e conjunturais da economia brasileira e possibilitam uma análise mais robusta das flutuações observadas nos principais indicadores financeiros.

2.2 Modelos de Equilíbrio Macroeconômico

Os modelos de equilíbrio macroeconômico oferecem uma estrutura teórica para compreender como diferentes mercados de bens, de moeda e de ativos interagem na determinação do produto, da taxa de juros e de outras variáveis agregadas. Entre os modelos mais influentes e amplamente utilizados na literatura econômica estão o modelo IS-LM e a hipótese de expectativas racionais. Ambos fornecem fundamentos importantes para a interpretação dos efeitos de variáveis macroeconômicas sobre os mercados financeiros, especialmente em contextos de formulação de política monetária e análise conjuntural.

2.2.1 IS-LM

O modelo IS-LM (Investment-Saving / Liquidity Preference-Money Supply), com base na Teoria Geral de Keynes, descreve o equilíbrio simultâneo nos mercados de bens e monetário (ASSOUS, 2007). A curva IS representa os pontos de equilíbrio no mercado de bens, onde a produção (PIB) é igual à demanda agregada — influenciada por consumo, investimento, gasto público e exportações líquidas. Já a curva LM reflete o equilíbrio no mercado monetário, onde a demanda por moeda é igual à oferta, dependente do nível de renda e da taxa de juros.

A intersecção entre as curvas IS e LM determina o nível de produto e a taxa de juros de equilíbrio da economia. Alterações em variáveis como política fiscal (deslocando a IS) ou política monetária (deslocando a LM) produzem efeitos previsíveis sobre o nível de atividade econômica e o custo do capital (KLEIN, 2000). Para este projeto, o modelo IS-LM é relevante pois sugere que mudanças na taxa Selic e nas expectativas sobre a política econômica afetam o nível de investimento, o consumo e, por consequência, o comportamento de ativos financeiros como o Ibovespa ou o câmbio.

2.2.2 Hipótese das expectativas racionais

Outro conceito fundamental para a análise macroeconômica e financeira é a hipótese das expectativas racionais. Segundo essa hipótese, os agentes econômicos formam suas expectativas de forma consistente com os modelos econômicos subjacentes, utilizando toda a informação disponível de maneira eficiente (DAVIDSON, 1982). Isso implica que os mercados ajustam rapidamente os preços dos ativos em resposta a novas informações — como mudanças esperadas na política monetária, inflação ou atividade econômica.

No contexto dos mercados financeiros, essa teoria é frequentemente associada à eficiência informacional dos preços dos ativos. A hipótese das expectativas racionais também fundamenta modelos como o de precificação de ativos (CAPM) e os modelos DSGE (Dynamic Stochastic General Equilibrium), além de justificar o uso de variáveis antecedentes como determinantes de variáveis financeiras (DIMSON; MUSSAVIAN, 1998).

Aqui, a incorporação desses modelos teóricos tem dois objetivos principais. Primeiro, serve como base para a seleção das variáveis independentes, assegurando coerência com a teoria econômica. Segundo, permite interpretar os resultados obtidos pelos modelos de aprendizado de máquina à luz de mecanismos econômicos bem estabelecidos. Assim, os efeitos identificados, como o impacto da variação dos juros sobre os retornos do Ibovespa, podem ser confrontados com as previsões desses modelos, reforçando a validade e a utilidade explicativa das estimativas obtidas.

2.3 Modelos de Precificação de Ativos

A teoria de precificação de ativos fornece os fundamentos analíticos para compreender como o risco e o retorno são relacionados nos mercados financeiros. Tais modelos são essenciais não apenas para decisões de investimento, mas também para a avaliação de políticas econômicas e análise do comportamento dos mercados. Neste projeto, a incorporação desses modelos permite interpretar os fatores que explicam variações em ativos financeiros, como o Ibovespa, à luz de relações teóricas consolidadas. Entre os modelos mais influentes estão o Capital Asset Pricing Model (CAPM) e a Arbitrage Pricing Theory (APT).

2.3.1 Capital Asset Pricing Model (CAPM)

O CAPM estabelece uma relação linear entre o retorno esperado de um ativo e seu risco sistemático em relação ao mercado (FRENCH, 2003). A equação fundamental do modelo é dada por:

$$E(R_i) = R_f + \beta_i \left[E(R_m) - R_f\right] \tag{2.1}$$

Onde $E(R_i)$ é o retorno esperado do ativo i, R_f é a taxa livre de risco, $E(R_m)$ é o retorno esperado do mercado, e β_i representa a sensibilidade do ativo às variações do mercado (risco sistemático). Segundo o CAPM, apenas o risco sistemático é precificado, pois o risco diversificável (específico) pode ser eliminado em carteiras bem diversificadas.

A relevância do CAPM para este estudo reside no fato de que variáveis macroeconômicas como taxa de juros, risco-país e inflação afetam tanto o retorno esperado do mercado quanto o prêmio de risco exigido pelos investidores. Assim, ao investigar os determinantes do retorno do Ibovespa, espera-se que mudanças nessas variáveis influenciem o comportamento dos investidores e, consequentemente, os preços dos ativos.

2.3.2 Arbitrage Pricing Theory (APT)

A Arbitrage Pricing Theory (APT), proposta por Ross (1976), oferece uma generalização do CAPM, permitindo múltiplos fatores de risco na explicação do retorno dos ativos (ROSS, 1976). Ao contrário do CAPM, que depende de um único fator de mercado, a APT assume que o retorno de um ativo pode ser descrito por uma combinação linear de diversos fatores macroeconômicos ou específicos, conforme representado por:

$$R_i = E(R_i) + \sum_{k=1}^{n} \beta_{ik} F_k + \varepsilon_i \tag{2.2}$$

Onde R_i é o retorno realizado do ativo i, $E(R_i)$ é o retorno esperado, F_k representa o valor do fator k, β_{ik} é a sensibilidade do ativo i ao fator k, e ε_i é o termo de erro idiossincrático.

A principal vantagem da APT está na sua flexibilidade (CHO; ELTON; GRUBER, 1984). Com isso, ela permite a inclusão de fatores observáveis como inflação, taxa de câmbio, crescimento do PIB e risco-país, que são as variáveis tratadas neste projeto. Dessa forma, a APT fornece um arcabouço teórico robusto para interpretar as relações encontradas nos modelos de aprendizado de máquina, especialmente quando se identifica, por exemplo, que o risco-país tem efeito negativo nos retornos do mercado acionário, ou que a taxa de câmbio exerce influência significativa sobre a atratividade dos ativos domésticos.

Ambos os modelos, CAPM e APT, fornecem uma base sólida para a construção e interpretação de modelos explicativos em finanças (SUN; ZHANG, 2001). Ao alinhar os resultados obtidos por técnicas modernas de inteligência artificial com essas teorias, busca-se não apenas melhorar o desempenho preditivo, mas também garantir coerência econômica e interpretabilidade nas análises realizadas.

2.4 Teoria dos Mercados Eficientes e Choques Macroeconômicos

A Teoria dos Mercados Eficientes (EMH – Efficient Market Hypothesis) postula que os preços dos ativos financeiros refletem, em todo momento, toda a informação disponível no mercado (FAMA, 1970). Isso implica que não seria possível obter retornos consistentemente superiores ao mercado utilizando apenas informação pública, uma vez que os preços se ajustam de forma imediata a qualquer nova informação.

Fama propôs três formas da eficiência de mercado. A forma fraca, na qual os preços refletem todas as informações históricas dos próprios preços, a forma semi-forte, na qual os preços incorporam toda a informação pública disponível (inclusive balanços, indicadores macroeconômicos, etc.) e, por fim, a forma forte, em que os preços refletem toda e qualquer informação — pública e privada (YEN; LEE, 2008).

A EMH tem implicações diretas para a análise de variáveis macroeconômicas em modelos financeiros. Se os mercados são eficientes na forma semi-forte, então indicadores como inflação, taxa de juros e PIB já estariam precificados nos ativos, restando pouca margem para obter ganhos sistemáticos com base nesses dados. No entanto, diversos estudos empíricos mostram evidências de anomalias de mercado e retornos previsíveis associados a choques econômicos, o que levanta questionamentos sobre o grau real de eficiência dos mercados — especialmente em economias emergentes como o Brasil, caracterizadas por maior volatilidade, menor transparência e assimetria informacional (BELO; BRASIL, 2006).

Neste contexto, os choques macroeconômicos assumem papel central na dinâmica dos preços de ativos. Choques são eventos inesperados que afetam diretamente as expectativas dos agentes econômicos e podem resultar em instabilidade econômica e financeira com efeitos relevantes sobre economias em desenvolvimento (DORNELAS; ARAGÓN, 2024). Esses choques podem ser de diversas naturezas, como política monetária, com alterações inesperadas na taxa Selic que afetam diretamente o custo do capital e o valuation dos ativos financeiros, inflação, que ao alterar a expectativa de retorno real, afetam a atratividade de ativos nominais, externos, com variações no preço das commodities ou no apetite ao risco global impactam fluxos de capitais, taxa de câmbio e risco-país, ou fiscais, eventos como crises políticas, reformas econômicas ou mudanças na percepção de solvência do governo impactam a confiança dos investidores.

Esses eventos podem ser capturados em modelos explicativos por meio de variáveis econômicas observáveis (ex.: salto na volatilidade cambial, aumento do EMBI+ Brasil, quebra na tendência do Ibovespa) ou por componentes não observados, inferidos por técnicas como modelos estruturais bayesianos ou árvores causais.

Para este projeto, a consideração da EMH e dos choques macroeconômicos oferece suporte teórico para investigar até que ponto as variáveis selecionadas são de fato relevantes na

explicação dos movimentos dos ativos. Além disso, ajuda a interpretar os resultados obtidos pelos modelos de inteligência artificial: se uma variável explicativa for estatisticamente relevante, é possível investigar se sua influência decorre de uma falha na eficiência de mercado, de um choque econômico específico ou de uma estrutura causal latente.

3 Modelagem Estatística e Econométrica

A análise de séries temporais e a modelagem econométrica tradicional constituem ferramentas fundamentais para investigar o comportamento de variáveis macroeconômicas e financeiras ao longo do tempo. Essas técnicas possibilitam não apenas a previsão de valores futuros, mas também a identificação de relações explicativas entre variáveis econômicas, assumindo estruturas estatísticas bem definidas. No contexto deste trabalho, os métodos estatísticos clássicos servem como linha de base (benchmark) para posterior comparação com modelos de inteligência artificial mais flexíveis.

3.1 Séries Temporais e Estacionaridade

Séries temporais são sequências de observações ordenadas no tempo, representadas como $y_t{}_{t=1}^{T}$, onde cada valor y_t corresponde a uma medição da variável em um instante de tempo t. A análise de séries temporais é fundamental em estudos econômicos e financeiros, pois permite modelar e prever o comportamento dinâmico de variáveis macroeconômicas e de mercado.

Um conceito-chave na modelagem de séries temporais é a estacionariedade. Uma série é dita estritamente estacionária quando sua distribuição conjunta não se altera com o tempo. Mais comumente, busca-se a estacionaridade em sentido amplo, em que a média, variância e autocovariância da série são constantes ao longo do tempo, refletindo alguma forma de equilíbrio estável (BEZERRA, 2006). A falta dessa propriedade pode causar regressões espúrias, em que relações estatisticamente significativas surgem entre variáveis que não possuem vínculo causal real.

Para tornar uma série estacionária, aplicam-se transformações apropriadas. Entre as mais comuns estão:

- **Primeira diferença**, utilizada especialmente em séries como taxa de juros e risco-país, define-se como:

$$\Delta y_t = y_t - y_{t-1} \tag{3.1}$$

- **Retorno logarítmico**, usado amplamente em preços de ativos financeiros como Ibovespa e câmbio, dado por:

$$r_t = \ln\left(\frac{y_t}{y_{t-1}}\right) \tag{3.2}$$

A verificação da estacionaridade é feita com testes estatísticos. Os principais são:

- **Teste de Dickey-Fuller Aumentado (ADF)**: tem como hipótese nula a presença de raiz unitária, isto é, a série não é estacionária. A rejeição da hipótese nula indica estacionaridade.
- **Teste KPSS (Kwiatkowski–Phillips–Schmidt–Shin)**: parte da hipótese nula de que a série é estacionária. Se essa hipótese for rejeitada, conclui-se que a série não é estacionária.

O uso conjunto dos testes ADF e KPSS fornece uma análise mais robusta, uma vez que suas hipóteses nulas são complementares (SCHLITZER, 1995). A aplicação desses testes é uma etapa metodológica fundamental para garantir que os modelos estatísticos sejam adequadamente especificados e que suas inferências sejam válidas.

No presente trabalho, foram aplicadas essas transformações e testes para garantir a adequação das séries temporais a modelos como regressões múltiplas e ARIMA (AutoRegressive Integrated Moving Average). O tratamento adequado da estrutura temporal dos dados contribui para evitar inferências inválidas e assegura a consistência das análises explicativas e preditivas que serão realizadas nas etapas seguintes.

3.2 Modelos ARIMA

Os modelos ARIMA (AutoRegressive Integrated Moving Average) são amplamente utilizados na modelagem e previsão de séries temporais univariadas. Eles combinam três componentes fundamentais, o AutoRegressivo (AR), que modela a dependência linear da série com base em seus próprios valores passados, a Integração (I), que representa o número de diferenciações necessárias para tornar a série estacionária e, por fim, a Média Móvel (MA), que incorpora a influência de choques passados (erros) sobre os valores futuros da série.

Um modelo ARIMA é denotado como ARIMA(p, d, q), onde p é a ordem do componente autorregressivo, d é o número de diferenciações aplicadas para atingir estacionaridade e q é a ordem do componente de média móvel.

A formulação geral do modelo ARIMA(p, d, q), após a diferenciação da série d vezes, pode ser escrita como:

$$\phi(L)(1-L)^d y_t = \theta(L)\varepsilon_t \tag{3.3}$$

Onde $\phi(L)$ é o polinômio autorregressivo no operador defasado L, isto é, $\phi(L) = 1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p$. $(1-L)^d$ representa a diferenciação de ordem d. $\theta(L)$ é o polinômio de média móvel, dado por $\theta(L) = 1 + \theta_1 L + \theta_2 L^2 + \cdots + \theta_q L^q$ e ε_t é o erro branco, assumido com média zero, variância constante e sem autocorrelação (CARDOSO, 2024).

A estimação de modelos ARIMA normalmente envolve a análise dos gráficos de autocorrelação (ACF) e autocorrelação parcial (PACF), para escolha adequada de p e q, a aplicação de testes de estacionariedade (ADF, KPSS) para definir d, a escolha do modelo ótimo com base em critérios de informação, como o AIC (Akaike Information Criterion) ou BIC (Bayesian Information Criterion) e, por fim, a avaliação dos resíduos do modelo (teste de Ljung-Box) para garantir ausência de autocorrelação nos erros.

Em geral, modelos ARIMA são eficazes para capturar a estrutura dinâmica interna de séries financeiras, como retornos de índices de mercado. No entanto, por serem univariados, não consideram influências externas sobre a variável dependente, o que limita sua capacidade explicativa no contexto de análise multivariada no sentido de que as previsões de valores futuros são limitadas a serem funções lineares das observações (NEWBOLD, 1983). Portanto, nesse caso, seria interessante contemplar uma classe mais ampla de modelos .

3.3 Regressão Linear Múltipla por MQO

A regressão linear múltipla, estimada por meio do método dos mínimos quadrados ordinários (MQO), é uma das técnicas estatísticas mais clássicas e amplamente utilizadas na análise econômica e financeira. Seu objetivo é modelar a relação entre uma variável dependente e um conjunto de variáveis explicativas, assumindo uma estrutura linear entre elas.

A forma geral do modelo pode ser expressa como:

$$y_t = \beta_0 + \beta_1 x_{1t} + \beta_2 x_{2t} + \cdots + \beta_k x_{kt} + \varepsilon_t \tag{3.4}$$

Onde y_t representa a variável dependente no tempo t (por exemplo, o retorno do Ibovespa), x_{it} são as variáveis explicativas (como variação da taxa de câmbio, risco-país, Selic, etc.), β_0 é o intercepto do modelo, β_i são os coeficientes associados a cada variável explicativa e ε_t é o termo de erro aleatório, assumido com média zero e variância constante (COELHO, 2014).

A estimação pelo método MQO consiste em minimizar a soma dos quadrados dos resíduos, isto é:

$$\min_{\boldsymbol{\beta}} \sum_{t=1}^{T} (y_t - \hat{y}_t)^2 \tag{3.5}$$

Esse processo produz estimadores eficientes sob os pressupostos clássicos do modelo linear, conhecidos como os pressupostos de Gauss-Markov, são eles: a linearidade na estrutura dos parâmetros, erros com média zero e variância constante (homocedasticidade), ausência de autocorrelação nos erros, ausência de multicolinearidade perfeita entre os regressores e normalidade dos erros (necessária para inferência exata via testes t e F).

A MQO constrói uma linha de melhor ajuste que serviria como a maneira mais precisa de representar a dispersão dos pontos de dados usando uma única linha (BURTON, 2021), quando aplicados a dados financeiros, especialmente de alta frequência, esses pressupostos frequentemente são violados. Por exemplo, resíduos não normalizados, presença de heterocedasticidade ou autocorrelação podem comprometer a validade das inferências estatísticas. Além disso, o modelo linear é limitado na captura de relações não lineares e interações complexas entre variáveis, o que motiva a utilização de abordagens mais flexíveis.

Ainda assim, a regressão linear múltipla desempenha um papel importante neste trabalho por fornecer uma linha de base explicativa clara e interpretável, contra a qual os modelos mais avançados baseados em aprendizado de máquina podem ser comparados.

3.4 Limitações e justificativa para modelos avançados

Apesar de sua utilidade, os modelos econométricos tradicionais apresentam limitações importantes, como a suposição de relações lineares entre variáveis, dificuldade de capturar efeitos não-lineares e interações complexas, sensibilidade a violações de pressupostos como heterocedasticidade e autocorrelação e a baixa flexibilidade para lidar com grandes volumes de variáveis explicativas (alta dimensionalidade).

A essas limitações soma-se uma restrição de natureza estrutural que merece reconhecimento explícito: a chamada Crítica de Lucas (LUCAS, 1976). Parâmetros estimados a partir de séries históricas refletem as regras de decisão dos agentes econômicos sob o regime de política vigente no período de estimação, de modo que mudanças sistemáticas de regime, sejam elas de natureza monetária, fiscal ou cambial, podem alterar essas regras e, por extensão, os próprios coeficientes capturados pelo modelo. Essa observação não invalida o uso da modelagem econométrica tradicional para descrever o regime histórico de treinamento, mas impõe cautela quando se pretende projetá-la sobre períodos atravessados por choques de natureza distinta.

Essas limitações motivam o uso de técnicas mais avançadas, como os modelos explicativos baseados em aprendizado de máquina, que serão apresentados na próxima seção. Essas abordagens permitem maior flexibilidade funcional, mantêm a interpretabilidade e são capazes de identificar estruturas relacionais complexas entre variáveis macroeconômicas e financeiras.

4 Modelos Explicativos com IA Interpretável

Nos últimos anos, o avanço das técnicas de aprendizado de máquina (machine learning) proporcionou novas ferramentas para a modelagem de fenômenos econômicos e financeiros. No entanto, grande parte desses modelos são considerados caixas-pretas, ou seja, fornecem alta acurácia preditiva, mas com pouca ou nenhuma interpretabilidade sobre como as variáveis influenciam os resultados.

Este trabalho adota uma abordagem alternativa: o uso de modelos de IA interpretável com foco explicativo, capazes de capturar relações complexas entre variáveis mantendo transparência na tomada de decisão. A seguir, são descritos três modelos centrais para este estudo: Generalized Additive Models (GAM), Bayesian Structural Time Series (BSTS) e Causal Forests.

A adoção dessa abordagem responde também a um conjunto convergente de pressões regulatórias e institucionais. No plano nacional, a Lei Geral de Proteção de Dados, em seu Art. 20, assegura ao titular o direito de revisão de decisões automatizadas que afetem seus interesses, incluindo expressamente as decisões de crédito, e exige do controlador a apresentação de informações claras sobre os critérios utilizados (Brasil, 2018). No arcabouço prudencial, o Conselho Monetário Nacional, por meio das Resoluções nº 4.557/2017 e nº 4.966/2021, impõe às instituições financeiras a obrigação de manter modelos quantitativos de risco auditáveis, com avaliação periódica de adequação e robustez (Banco Central do Brasil, 2017; Banco Central do Brasil, 2021), sendo que a segunda resolução, em vigor desde 2025, introduziu o regime de perdas esperadas em consonância com o IFRS 9 e intensificou a demanda por modelos preditivos verificáveis pelo regulador. No plano internacional, supervisores como o Bank of England já operacionalizam técnicas de explicabilidade, como a decomposição via valores de Shapley em modelos de risco de inadimplência, em sua validação prudencial (BRACKE et al., 2019), e revisões sistemáticas recentes em XAI financeira documentam a convergência crescente entre exigências normativas e práticas de modelagem (ČERNEVIčIENė; KABAšINSKAS, 2024).

Essa convergência sustenta uma distinção operacional importante para o restante deste capítulo. BüCKER et al. (2022) caracterizam três conceitos frequentemente conflados na literatura: transparência (modelos cujo funcionamento é diretamente legível), auditabilidade (modelos cujo comportamento é verificável por terceiros) e explicabilidade (decisões individuais justificáveis a posteriori). Os modelos selecionados neste trabalho, a saber, GAM, BSTS e Causal Forests, pertencem majoritariamente à categoria de modelos intrinsecamente interpretáveis, embora em sentidos distintos entre si. GAM e BSTS apresentam transparência estrutural em sentido estrito: seus mecanismos internos são diretamente legíveis, seja pela decomposição adi-

tiva das funções suavizadas no primeiro caso, seja pela decomposição explícita em componentes latentes com distribuições posteriores no segundo. O Causal Forest ocupa posição diferenciada nesse espectro: sua interpretabilidade é de natureza causal e opera ao nível das saídas, uma vez que a própria estimativa $\tau(x)$ constitui a quantidade de interesse econômico, dispensando qualquer explicação post hoc aplicada sobre uma predição opaca. Essa distinção, que será retomada ao final desta seção, não compromete o critério central de seleção dos modelos — a recusa ao uso de métodos que dependem de atribuição retrospectiva de importância sobre mecanismos internos inacessíveis —, mas exige reconhecimento explícito quanto ao tipo de transparência que cada modelo oferece. A escolha do conjunto está alinhada tanto à literatura recente em score de crédito (BRACKE et al., 2025) quanto ao critério de adequação prudencial discutido acima. Cumpre, portanto, descrever cada um deles em detalhe.

4.1 Generalized Additive Models (GAM)

Os Generalized Additive Models (GAM), são uma extensão dos modelos lineares generalizados que permitem a modelagem não linear e aditiva entre a variável dependente e os preditores. A forma geral de um GAM é dada por:

$$g(E[Y]) = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_k(x_k) \tag{4.1}$$

Onde $g(\cdot)$ é uma função de ligação apropriada à distribuição da variável resposta, β_0 é o intercepto e$f_j(x_j)$ são funções suavizadas (geralmente splines) aplicadas a cada variável preditora x_j (YANG et al., 2023).

Os GAMs são particularmente úteis por permitirem uma análise marginal do efeito de cada variável sobre a resposta, facilitando a visualização de relações não lineares. No contexto econômico, por exemplo, pode-se observar de forma clara como o risco-país afeta os retornos do Ibovespa de maneira não proporcional.

Uma característica fundamental dos GAMs é a interpretabilidade de seus componentes, pois cada função pode ser analisada isoladamente para compreender o efeito marginal do preditor correspondente sobre a variável resposta. Isso permite visualizar e interpretar como variações em x_j impactam o resultado esperado, sem que os efeitos de outros preditores sejam confundidos, uma vez que o modelo é aditivo. Essa transparência é particularmente valiosa no contexto econômico e financeiro, onde entender o impacto das variáveis explicativas, como indicadores macroeconômicos ou índices de risco, é tão importante quanto a capacidade preditiva.

Por exemplo, ao modelar o retorno do índice Ibovespa, um GAM pode revelar que o efeito do risco-país não é linear, apresentando regiões de maior sensibilidade em determinados níveis do risco e uma saturação do efeito em outros, fenômeno que um modelo linear não conseguiria capturar. Além disso, a estrutura aditiva do modelo facilita a detecção de relações

não monotônicas e efeitos de limiar, enriquecendo a análise econômica.

Assim, os GAMs constituem uma ferramenta poderosa para a modelagem explicativa, combinando flexibilidade na captura de padrões complexos com interpretabilidade, o que se alinha aos objetivos deste trabalho de construir modelos de IA interpretáveis que expliquem os impactos de variáveis econômicas sobre indicadores financeiros.

4.2 Bayesian Structural Time Series (BSTS)

O modelo Bayesian Structural Time Series (BSTS), desenvolvido por Scott e Varian (2014), é uma abordagem flexível para modelar séries temporais com estrutura latente. A ideia central é decompor a série em componentes estruturais como tendência, sazonalidade e efeitos de regressão, incorporando inferência bayesiana para estimar suas incertezas (SCOTT; VARIAN, 2014).

O caráter bayesiano do BSTS permite a incorporação de conhecimento prévio e a obtenção de distribuições para os parâmetros do modelo e para os estados latentes, oferecendo uma quantificação explícita da incerteza nas estimativas. Isso é particularmente vantajoso em análises econômicas e financeiras, onde as condições de mercado podem mudar abruptamente e a modelagem precisa refletir essa volatilidade.

Além disso, o BSTS é amplamente empregado em análises de causalidade temporal, especialmente na metodologia conhecida como causal impact analysis, que busca estimar o efeito de intervenções, políticas ou choques exógenos sobre uma série temporal, mesmo na ausência de um grupo de controle clássico. Dentro deste projeto, o BSTS é utilizado para modelar o impacto dinâmico e temporal de variáveis macroeconômicas, como a taxa Selic e a inflação, sobre indicadores financeiros brasileiros, permitindo capturar não apenas a magnitude, mas também a evolução temporal dessas influências, com um rigor probabilístico que favorece decisões informadas e transparentes.

4.3 Causal Forests

As Causal Forests são uma extensão dos algoritmos de florestas aleatórias desenvolvidas para fins de inferência causal heterogênea. Essas florestas têm como objetivo principal estimar o efeito causal condicional de um "tratamento"sobre um desfecho, considerando as características específicas de cada observação.

Ao contrário dos modelos tradicionais de aprendizado supervisionado, que buscam prever uma variável de interesse, a Causal Forest busca estimar o valor de:

$$\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x] \tag{4.2}$$

Onde $Y(1)$ e $Y(0)$ representam os resultados potenciais com e sem tratamento, respectivamente, X é o vetor de covariáveis observadas e $\tau(x)$ é o efeito médio condicional de tratamento (Conditional Average Treatment Effect – CATE) para indivíduos com características $X = x$.

O algoritmo constrói múltiplas árvores de decisão, cada uma particionando os dados de forma a maximizar a diferença estimada de tratamento entre subgrupos homogêneos. A média ponderada das estimativas obtidas em cada árvore fornece uma estimativa final do efeito causal heterogêneo para cada ponto de observação (ATHEY; WAGER, 2019).

No contexto deste projeto, o uso de Causal Forests permite investigar como o impacto de variáveis macroeconômicas (como a taxa Selic, o risco-país ou o câmbio) sobre retornos do Ibovespa pode variar em diferentes condições econômicas. Por exemplo, pode-se estimar se o efeito de um aumento na taxa de juros difere dependendo do nível de inflação, da tendência do mercado ou da volatilidade observada.

Causal Forest é um método que está crescendo em uso e que está sendo usado de maneiras interessantes e valiosas em muitos campos diferentes (REHILL, 2024). A principal vantagem do método está em sua capacidade de estimar efeitos causais em ambientes observacionais complexos, capturar heterogeneidade no impacto de variáveis explicativas e manter interpretabilidade local, através da análise das estimativas de $\tau(x)$ para subgrupos específicos. Do ponto de vista das garantias teóricas, WAGER; ATHEY (2018) demonstram que, sob a condição de estimação honesta introduzida por ATHEY; IMBENS (2016), os estimadores do Causal Forest são pontualmente consistentes para o efeito causal verdadeiro $\tau(x)$ e possuem distribuição amostral assintoticamente gaussiana e centrada, propriedades que permitem a construção de intervalos de confiança assintoticamente válidos para o efeito condicional de tratamento.

Essa abordagem é particularmente relevante para mercados financeiros, onde os efeitos de políticas econômicas ou choques externos raramente são uniformes, e a resposta dos ativos depende de múltiplos fatores contextuais. O uso de Causal Forests, portanto, complementa os modelos anteriores ao trazer uma dimensão causal robusta e personalizada para a análise.

Cabe, porém, reconhecer uma tensão metodológica que esta escolha carrega. A estrutura interna do Causal Forest é a de um ensemble de centenas de árvores de decisão que particiona recursivamente o espaço de covariáveis, arquitetura que, do ponto de vista mecanístico, assemelha-se aos modelos opacos criticados ao longo deste capítulo.

A distinção relevante não está na legibilidade dos mecanismos internos, mas na natureza da saída produzida. Ao estimar diretamente $\tau(x)$, o efeito causal condicional, o método entrega como resultado a própria quantidade econômica de interesse, sem que seja necessário aplicar, a posteriori, técnicas de atribuição de importância sobre uma predição opaca. Esse tipo de interpretabilidade, orientada pela saída causal e não pela transparência dos componentes internos, difere do que GAM e BSTS oferecem, mas preserva o critério que orienta a seleção metodoló-

gica deste trabalho: a recusa de explicações retrospectivas sobre modelos cujo funcionamento interno é inacessível.

Essa distinção é, todavia, uma limitação declarada. O Causal Forest não é transparente em sentido estrutural e, em contextos que exijam auditabilidade dos mecanismos de particionamento das árvores, essa opacidade interna permanece como restrição relevante.

Apesar das vantagens interpretativas dos três modelos descritos, cabe reconhecer uma limitação que opera além das dimensões estatísticas usuais. A chamada Crítica de Lucas (LUCAS, 1976) sustenta que os parâmetros estimados a partir de séries históricas refletem, no fundo, as regras de decisão dos agentes econômicos sob o regime de política vigente no período de estimação, de modo que mudanças sistemáticas de política, sejam elas monetárias, fiscais ou cambiais, podem alterar essas regras e, por consequência, as próprias relações que o modelo capturou. Modelos de aprendizado de máquina, ainda que mais flexíveis do que os econométricos tradicionais, herdam essa restrição na medida em que aprendem padrões estatísticos em séries históricas sem microfundamentação econômica explícita, o que torna a leitura de suas estimativas como simulação contrafactual de políticas econômicas particularmente delicada.

A magnitude empírica dessa restrição é uma questão em aberto. Avaliações em modelos de política monetária sugerem que, em períodos de regime estável, a instabilidade dos parâmetros pode ser modesta (RUDEBUSCH, 2005), ao passo que em transições de regime ela se manifesta com clareza estatística (LUBIK; SURICO, 2010). Estudos contemporâneos aplicados a aprendizado de máquina sugerem ainda que algoritmos de ML aproximam expectativas racionais diante de choques pequenos a moderados, mas falham sistematicamente em mudanças paradigmáticas, justamente porque o passado não contém análogos suficientes para esses regimes (CASTELNUOVO; GALIMBERTI; SUARDI, 2022). Nesse contexto, as Causal Forests apresentam-se como uma tentativa explícita de aproximar a inferência estrutural a partir de aprendizado de máquina, ao tratar a estimação de efeitos causais condicionais como problema de identificação, e não apenas de predição, com hipóteses adicionais sobre o mecanismo de tratamento (ATHEY; IMBENS, 2019). Esses elementos enquadram, no capítulo de resultados, a leitura do desempenho dos modelos no período de teste 2020–2024, marcado por choques de magnitude elevada, como a pandemia, o ciclo de aperto monetário com a Selic atingindo 13,75% ao ano e a recomposição cambial subsequente.

5 Metodologia

Este capítulo descreve as etapas metodológicas realizadas nas fases iniciais do projeto, voltadas à investigação dos fatores econômicos que explicam o comportamento de variáveis financeiras no Brasil. As atividades aqui relatadas incluem a construção da base de dados, o tratamento estatístico preliminar das variáveis e a aplicação de modelos econométricos tradicionais como linha de base para futuras análises com métodos de inteligência artificial interpretável.

5.1 Coleta e Tratamento de Dados

A primeira etapa metodológica consistiu na construção de uma base de dados abrangente e com frequência diária, com o objetivo de capturar de forma granular e dinâmica os principais movimentos do mercado financeiro brasileiro. As variáveis selecionadas refletem fundamentos macroeconômicos e financeiros amplamente reconhecidos na literatura, tais como:

- Taxa Selic (juros básicos);
- Taxa de câmbio (dólar comercial);
- IPCA (inflação ao consumidor);
- PIB;
- Ibovespa (índice da bolsa brasileira);
- Risco-País (medido pelo EMBI+).

A coleta foi realizada com auxílio de bibliotecas Python como python-bcb, ipeadatapy e yfinance. As séries com frequência mensal ou trimestral (ex: IPCA, PIB) foram interpoladas linearmente para frequência diária. Em casos de ausência de dados em dias não úteis, foi utilizado o método forward fill. A base final foi consolidada em um único DataFrame, alinhado com os dias de pregão da B3, tendo o índice do Ibovespa como referência de calendário. A Tabela 1 apresenta as estatísticas descritivas das séries em seus valores originais, antes de qualquer transformação de estacionariedade, oferecendo uma visualização inicial da escala, variabilidade e amplitude de cada variável ao longo do período amostral.

Essa padronização permite a análise sincronizada entre as variáveis e evita perda de informações relevantes em eventos de curto prazo.

Estatística	br_selic	br_dolar	br_ipca	br_pib	br_ibov	embi_brasil	ipca_expect.
Obs.	6279	6279	300	300	6191	6335	5811
Média	0,0453	3,085	0,501	4,27e+05	60859	390,3	0,386
Desv. pad.	0,0176	1,259	0,395	2,56e+05	34526	307,5	0,121
Mínimo	0,0075	1,535	−0,680	9,14e+04	8371	136	0,130
25%	0,0338	2,034	0,260	1,95e+05	35833	221	0,300
Mediana	0,0447	2,726	0,450	4,00e+05	56864	271	0,370
75%	0,0567	3,863	0,675	5,85e+05	84125	418	0,460
Máximo	0,0929	6,199	3,020	1,05e+06	137344	2443	0,850

Tabela 1 – Estatísticas descritivas das séries brutas antes das transformações de estacionariedade. Selic: valor diário da taxa anual; câmbio: R$/US$ (dólar comercial); IPCA: variação mensal (%); PIB: R$ milhões correntes (trimestral, interpolado); Ibovespa: pontos; EMBI+: pontos-base; expectativa IPCA: % ao mês (Fonte: Autor).

5.2 Análise Exploratória e Testes de Estacionariedade

A segunda etapa metodológica teve como objetivo compreender as propriedades estatísticas das variáveis e garantir as condições necessárias para a aplicação de modelos estatísticos válidos, especialmente no contexto de séries temporais.

5.2.1 Análise de Correlação

Antes de aplicar modelos econométricos às variáveis macroeconômicas e financeiras selecionadas, foi realizada uma análise exploratória com foco na correlação entre as séries. Inicialmente, calculou-se a matriz de correlação de Pearson das séries em seus níveis originais (sem transformação). O resultado revelou correlações artificialmente elevadas, como entre PIB e Ibovespa ($\rho = 0{,}92$), sinalizando o risco de regressões espúrias devido à presença de tendências comuns de longo prazo nas séries não estacionárias.

Para contornar esse problema, foi construída uma nova base de dados contendo as séries transformadas, com o objetivo de garantir a estacionariedade e a validade estatística dos modelos subsequentes. As transformações foram implementadas da seguinte forma: a variável IPCA foi mantida em seu formato original, pois já se comportava como uma série estacionária. Para variáveis representando preços ou índices, como Ibovespa e PIB, foi calculado o retorno logarítmico, conforme a equação:

$$r_t = \ln(y_t) - \ln(y_{t-1}) = \ln\left(\frac{y_t}{y_{t-1}}\right) \tag{5.1}$$

Para as demais variáveis, como taxa Selic, câmbio e risco-país (EMBI+), foi aplicada a primeira diferença simples, segundo:

$$\Delta y_t = y_t - y_{t-1} \tag{5.2}$$

Essas transformações foram implementadas com base na natureza econômica de cada variável e sua dinâmica esperada ao longo do tempo. O código em Python utilizou condições para aplicar a transformação adequada a cada coluna da base original, gerando um novo DataFrame consolidado com as versões estacionarizadas das variáveis.

Após a transformação, foi descartada a primeira linha do conjunto de dados, que continha valores nulos resultantes da diferenciação. Em seguida, a matriz de correlação das séries transformadas foi recalculada, e os resultados mostraram relações mais fracas, porém mais consistentes com a teoria econômica. Destaca-se a correlação negativa entre a variação do dólar e o retorno do Ibovespa ($\rho = -0{,}34$), compatível com o entendimento de que a desvalorização cambial tende a reduzir a atratividade do mercado acionário brasileiro.

Essas transformações não apenas aumentaram a robustez estatística das análises, como também respeitaram os fundamentos econômicos, ajustando a modelagem às propriedades dinâmicas de cada variável.

5.2.2 Testes de Estacionariedade

Para garantir que as séries transformadas fossem adequadas à modelagem econométrica, foram aplicados os seguintes testes:

- **Teste de Dickey-Fuller Aumentado (ADF)** — Hipótese nula: presença de raiz unitária (não estacionária);
- **Teste KPSS** — Hipótese nula: estacionariedade.

Os testes realizados sobre as séries transformadas indicaram estacionariedade estatística para todas as variáveis, com p-valores baixos no ADF e altos no KPSS, confirmando que os dados estavam apropriados para a modelagem subsequente.

Com o objetivo de validar a robustez da interpolação linear aplicada às séries de PIB e IPCA, foi conduzido um teste de sensibilidade comparando três métodos distintos de interpolação para frequência diária: interpolação linear, forward fill e interpolação por spline cúbico. Para cada método, os testes ADF e KPSS foram reaplicados às séries resultantes. Os diagnósticos de estacionariedade mostraram-se consistentes entre os três métodos, confirmando que a escolha da interpolação linear não introduziu viés direcional nos dados e que as conclusões sobre estacionariedade são robustas à metodologia de interpolação adotada. Cabe registrar, porém, que qualquer método de interpolação essencialmente cria dados onde não existem observações diárias reais; como extensão natural deste trabalho, a substituição do PIB interpolado por proxies com periodicidade intrinsecamente mais alta — como o Índice de Atividade Econômica do Banco Central (IBC-Br, disponível mensalmente) ou indicadores de alta frequência como consumo de energia elétrica e fluxo de pedágio — permitiria reduzir esse ruído de interpolação,

ancorando as covariáveis de atividade econômica em movimentos mais aderentes à realidade do período.

5.3 Modelagem Econométrica Tradicional

A terceira fase do projeto consistiu na aplicação de modelos econométricos clássicos com dois objetivos principais: (i) estabelecer uma linha de base (benchmark) para posterior comparação com modelos baseados em IA, e (ii) obter os primeiros insights explicativos sobre a dinâmica entre as variáveis macroeconômicas e o mercado financeiro.

5.4 Análise Exploratória Direcionada

Antes de configurar os modelos de IA interpretável, foi conduzida uma análise exploratória direcionada sobre o conjunto de dados transformado (`br_transformado`), com foco nos aspectos que mais diretamente impactam as escolhas metodológicas dos modelos subsequentes: escala e esparsidade das covariáveis, correlação com o alvo, multicolinearidade e estrutura de autocorrelação da série-alvo. Toda a análise opera exclusivamente sobre o conjunto de treino (2001–2019), preservando o conjunto de teste sem contaminação.

5.4.1 Escala, Esparsidade e Correlação com o Alvo

Uma primeira inspeção das estatísticas descritivas das covariáveis revelou assimetria expressiva de escala. A variação do risco-país (ΔEMBI+, `embi_brasil_diff`) apresentou desvio padrão de 17,36, cerca de 500 vezes maior do que as demais covariáveis (dólar: 0,034; expectativa de IPCA: 0,018; PIB: 0,002; Selic: 0,0004). Essa diferença de escala, se não tratada, pode distorcer regularizações que assumem coeficientes em escala comparável, como o encolhimento bayesiano uniforme do BSTS.

Além da escala, duas covariáveis exibiram alta concentração em zero: ΔSelic (`br_selic_diff`) com 87,1% dos valores iguais a zero, e ΔExpectativa de IPCA (`ipca_expectativa_diff`) com 67,5%. Essa esparsidade reflete a natureza dos respectivos instrumentos: a taxa Selic é ajustada nas reuniões do Copom, que ocorrem a cada 45 dias em média, e as expectativas de inflação são frequentemente revisadas apenas em episódios de choque. Em modelos lineares, variáveis com baixa variância efetiva tendem a contribuir pouco para o ajuste, embora possam carregar sinal informativo nos dias em que variam.

A correlação de Pearson e Spearman entre cada covariável e o retorno logarítmico do Ibovespa (`br_ibov_ret_log`) confirmou a relevância esperada das duas variáveis de maior magnitude: ΔEMBI+ apresentou $\rho_{\text{Pearson}} = -0{,}4039$ e $\rho_{\text{Spearman}} = -0{,}4393$ ($p < 0{,}001$); ΔCâmbio apresentou $\rho_{\text{Pearson}} = -0{,}3394$ e $\rho_{\text{Spearman}} = -0{,}3168$ ($p < 0{,}001$). As demais covariáveis (ΔExpectativa IPCA, Retorno PIB, IPCA e ΔSelic) não apresentaram correlação es-

tatisticamente significativa com o alvo (p $\geq$ 0,25 em Spearman), o que é coerente com a alta proporção de zeros nas séries de menor frequência.

A ausência de multicolinearidade relevante foi confirmada pelo Fator de Inflação da Variância (VIF) máximo de 1,14 entre todas as covariáveis, descartando a necessidade de eliminação por redundância linear.

5.4.2 Autocorrelação do Alvo e Defasagem dos Regressores

A estrutura de autocorrelação da série-alvo foi investigada por meio de correlações seriais e do teste de Ljung-Box. As autocorrelações do retorno logarítmico do Ibovespa foram fracas em magnitude: lag 1 ($-0{,}049$), lag 2 ($+0{,}006$), lag 5 ($+0{,}014$) e lag 10 ($+0{,}035$). Apesar dos valores baixos, o teste de Ljung-Box indicou estrutura autocorrelacional residual significativa (estatística $= 20{,}6$ no lag 5 e $= 43{,}8$ no lag 10; p $<$ 0,001 em ambos os casos), sinalizando que o ruído da série não é inteiramente livre de memória.

A análise de correlações cruzadas com defasagem 1, 2 e 5 das covariáveis revelou que o sinal das variáveis macroeconômicas é essencialmente contemporâneo: as correlações entre os valores defasados das covariáveis e o retorno do dia seguinte foram consistentemente inferiores às correlações contemporâneas. Esse achado desencoraja a inclusão sistemática de versões defasadas das covariáveis como preditores, mas, ao mesmo tempo, a autocorrelação significativa de lag 1 da própria série-alvo motiva a inclusão de uma *feature* autorregressiva (`ibov_lag1`) nos modelos que se beneficiam de preditores adicionais, como o GAM e o BSTS.

5.4.3 Implicações Metodológicas

Os achados da análise exploratória orientaram diretamente três decisões de configuração adotadas nos modelos seguintes. Primeiro, a discrepância de escala do ΔEMBI+ motivou o uso de um *prior* heterogêneo no BSTS, com amplitude dez vezes maior para esse regressor do que para os demais, evitando que o encolhimento uniforme suprima seu efeito. Segundo, a autocorrelação significativa de lag 1 da série-alvo justificou a inclusão de `ibov_lag1` como covariável adicional no GAM (experimento G8) e no BSTS, com ganho confirmado de desempenho *out-of-sample*. Terceiro, a ausência de multicolinearidade relevante (VIF $\leq$ 1,14) dispensou qualquer eliminação prévia de variáveis por redundância linear, permitindo que os modelos realizem sua própria seleção com base em critérios estatísticos nativos.

5.5 Avaliação Out-of-Sample e Validação Temporal

Para que as métricas de desempenho reflitam a capacidade preditiva real dos modelos e não apenas a qualidade de ajuste sobre os dados de estimação, foi adotada uma estratégia de avaliação *out-of-sample* com corte temporal estrito. Em séries temporais financeiras, a avalia-

ção *in-sample*, em que o modelo é ajustado e avaliado no mesmo conjunto de dados, tende a subestimar o risco de sobreajuste (*overfitting*), pois permite que o modelo incorpore padrões específicos do período de treino que não necessariamente se reproduzem em dados futuros.

O corte temporal adotado foi 01/01/2020, dividindo os dados em:

- **Conjunto de treino:** de novembro de 2001 a dezembro de 2019, totalizando 4.481 observações diárias. Esse período cobre ciclos distintos de política monetária, incluindo a fase de juros elevados nos anos 2000, a crise financeira global de 2008 e o ciclo de redução da Selic iniciado em 2016, proporcionando ao modelo exposição a diferentes regimes econômicos.
- **Conjunto de teste:** de janeiro de 2020 a julho de 2024, totalizando 1.117 observações diárias. Esse período inclui eventos sem precedente no histórico de treino: a pandemia de COVID-19 (2020), o ciclo de aperto monetário que elevou a Selic a 13,75% ao ano entre 2021 e 2023, e o processo de normalização gradual em 2024.

A escolha do corte em 2020 é metodologicamente relevante por dois motivos. Primeiro, o período de teste concentra choques de natureza distinta dos presentes no treino, tornando-o um avaliador mais rigoroso da capacidade de generalização. Segundo, todos os modelos estimados neste trabalho utilizam o mesmo corte, garantindo comparabilidade direta entre as métricas de desempenho.

Os modelos estimados *in-sample* sobre o conjunto completo de dados servem como linha de base referencial. Para fins de comparação *out-of-sample*, cada modelo foi retreinado exclusivamente nos dados de treino e avaliado no conjunto de teste, com as métricas R^2, MAE e RMSE calculadas sobre observações não utilizadas na estimação.

A robustez das métricas obtidas nesse split único foi também investigada por meio de *walk-forward cross-validation* com janela expansiva (seis dobras, testes de dois anos cada, cobrindo 2010–2021). Dois resultados merecem leituras distintas. O desvio padrão do R^2 do GAM entre as dobras foi de 0,086, acima do limiar de estabilidade de 0,05 adotado como critério de adoção — o que não reforça a estabilidade do modelo, mas sim o oposto: significa que o desempenho preditivo absoluto varia substancialmente com o regime econômico, resultado coerente com a Crítica de Lucas já discutida neste capítulo. O fold correspondente ao período COVID (2020–2021) apresentou o maior R^2 de todas as dobras (0,378 para o GAM), enquanto os períodos de menor volatilidade (2012–2015) produziram os menores (0,16–0,19). O que de fato reforça a conclusão principal do trabalho é um resultado distinto: o ranking relativo entre os modelos (GAM $>$ OLS $>$ BSTS) manteve-se estável nas seis dobras, indicando que, embora o nível absoluto de R^2 flutue com o regime, a ordenação dos métodos é robusta ao longo do período amostral.

A escolha pela janela fixa, em detrimento de estratégias adaptativas, exige enquadramento metodológico explícito. A literatura sobre seleção de janelas em previsão fora da amostra com parâmetros variantes no tempo reconhece que, em ambientes com instabilidade estrutural real, janelas *rolling* ou adaptativas podem superar janelas fixas no critério preditivo, ao passo que, em séries com regime estável, a diferença tende a ser marginal (INOUE; JIN; ROSSI, 2017). A dispersão dos R^2 do GAM entre as dobras da *walk-forward* indica que o caso brasileiro apresenta, de fato, sinais de instabilidade que, no plano teórico, são coerentes com a Crítica de Lucas (LUCAS, 1976), segundo a qual mudanças sistemáticas de política podem alterar os parâmetros que o modelo capturou em um regime anterior. A adoção da janela fixa neste trabalho privilegia a comparabilidade direta entre modelos e a simplicidade da avaliação, com a contrapartida de que a leitura das métricas *out-of-sample* deve ser feita à luz dessa tensão. A exploração formal de janelas adaptativas figura entre as extensões naturais discutidas no capítulo de conclusão.

5.6 Otimização e Configuração do Modelo GAM

O Modelo Aditivo Generalizado (GAM) foi estimado com a biblioteca `pyGAM` (Python), utilizando os dados do conjunto de treino definido na seção anterior. A variável dependente é o retorno logarítmico diário do Ibovespa (`br_ibov_ret_log`) e as covariáveis são as mesmas variáveis transformadas utilizadas no modelo OLS.

A estimação do GAM envolveu quatro etapas de refinamento metodológico. As duas primeiras (seleção do número de splines e da forma funcional por variável) foram orientadas pelo MAE em um *holdout* interno (jan/2018–dez/2019), partição reservada exclusivamente para esse fim e mantida separada do conjunto de teste, evitando que as escolhas de configuração favoreçam o ajuste *in-sample*. As duas etapas seguintes (substituição do IPCA em nível por primeiras diferenças e inclusão de uma *feature* autorregressiva de defasagem 1) foram validadas pelo critério A/B contra o *baseline* operacional, comparando desempenho no conjunto de teste.

5.6.1 Seleção do número de splines (*n_splines*)

O hiperparâmetro *n_splines* determina o número de funções de base aplicadas em cada suavização, controlando a flexibilidade das curvas ajustadas. Valores reduzidos produzem funções mais suaves, com menor risco de sobreajuste, enquanto valores maiores permitem ao modelo capturar padrões mais complexos, ao custo de maior variância nas estimativas.

Para identificar o valor ótimo, foi realizada uma busca sistemática no conjunto $\{5, 10, 15, 20, 25\}$, treinando o GAM com todos os termos do tipo $s(\cdot)$ no subconjunto de ajuste (2001–2017) e avaliando o MAE no *holdout* (2018–2019) para cada configuração. O valor com menor MAE no *holdout* foi selecionado e utilizado nas etapas subsequentes.

5.6.2 Seleção do tipo de termo por variável (*smooth* vs. linear)

Com o $n_splines$ ótimo definido, foi conduzida uma análise variável a variável para determinar se a representação não linear, por meio de spline $s(\cdot)$, gerava ganho de desempenho em relação a um termo linear $l(\cdot)$. Para cada variável j, o MAE no *holdout* 2018–2019 foi calculado mantendo-se aquela variável com o tipo em avaliação (s ou l) e todas as demais com suas configurações de referência (s com $n_splines$ ótimo). O ganho não linear foi definido como:

$$\Delta\text{MAE}_j = \text{MAE}_{l(j)} - \text{MAE}_{s(j)} \tag{5.3}$$

Onde $\text{MAE}_{l(j)}$ e $\text{MAE}_{s(j)}$ representam o erro médio absoluto no *holdout* ao se utilizar, respectivamente, termo linear e termo suavizado para a variável j. Valores positivos de ΔMAE_j indicam que a não linearidade beneficia o ajuste; valores negativos ou nulos indicam que o termo linear é suficiente. Os resultados dessa análise são apresentados na Seção 7.2.

5.6.3 Ajustes Adicionais: Transformação do IPCA e Variável Autorregressiva

Duas melhorias foram validadas em sequência após o processo de seleção de termos. A primeira consistiu em substituir o IPCA em nível (`br_ipca`) por sua primeira diferença, corrigindo a inconsistência entre variáveis em nível e em diferença no vetor de preditores. A segunda adicionou uma *feature* autorregressiva de defasagem 1 (`ibov_lag1`), definida como o retorno logarítmico do pregão anterior, capturando autocorrelação de curto prazo que os termos macroeconômicos não cobrem. Ambas foram aceitas pelo critério A/B comparando R^2, MAE e RMSE no conjunto de teste. Os resultados do processo completo de otimização e o desempenho do modelo final são apresentados no Capítulo de Resultados.

5.7 Configuração e Estimação do Modelo BSTS

O modelo Bayesian Structural Time Series (BSTS) foi estimado utilizando a biblioteca `orbit-ml` (Python), por meio do estimador `DLT` (Damped Local Trend), que decompõe a série em três componentes estruturais: tendência, sazonalidade e regressão. A variável dependente e o conjunto de covariáveis são os mesmos utilizados nos modelos OLS e GAM, garantindo comparabilidade direta entre os modelos. A estimação foi conduzida sobre o conjunto de treino (2001–2019) e a avaliação *out-of-sample* foi realizada no conjunto de teste (2020–2024), preservando o corte temporal definido na Seção anterior.

A inferência foi realizada por meio de amostragem MCMC (*Markov Chain Monte Carlo*) implementada via Stan, com quatro cadeias paralelas, 500 iterações de *warmup* e 500 amostras posteriores por cadeia. A sazonalidade foi fixada em cinco pregões, correspondendo

ao ciclo semanal de negociação. A adequação dessa escolha foi verificada por uma análise de sensibilidade em que o período sazonal variou entre 5, 10, 21 e 22 pregões: as diferenças em MAE *out-of-sample* entre as configurações foram inferiores a 0,2%, e o espectro de potência da série de retornos não identificou pico dominante em nenhuma das frequências candidatas, indicando ausência de ciclo sazonal estruturalmente relevante; diante desse resultado, a configuração semanal foi mantida por parcimônia e por ser a referência convencional em séries financeiras diárias. O ajuste do BSTS envolveu três etapas sequenciais, descritas a seguir.

5.7.1 Seleção de Variáveis via Intervalos de Credibilidade

Diferentemente do GAM, em que a análise por variável é feita comparando MAE *out-of-sample*, o BSTS oferece um critério probabilístico nativo: a distribuição posterior de cada coeficiente de regressão. Para cada preditor, foi calculado o intervalo de credibilidade a 90% a partir das amostras posteriores. Uma variável é considerada relevante se seu IC 90% não contém o zero, isto é, se a probabilidade de seu efeito ter sinal consistente excede 0,9.

Esse critério bayesiano substitui o teste de significância clássico por uma inferência baseada na concentração de massa probabilística. Variáveis cujos intervalos de credibilidade cruzam o zero são removidas do modelo final, reduzindo dimensionalidade sem recurso a ajustes *ad hoc*.

5.7.2 Otimização do hiperparâmetro *sigma_prior*

O hiperparâmetro `sigma_prior` controla a força do encolhimento bayesiano (*shrinkage*) aplicado aos coeficientes de regressão. Valores baixos impõem priores mais informativas e concentradas em torno de zero, regularizando o modelo; valores altos relaxam essa restrição, permitindo coeficientes maiores em magnitude.

Para identificar o valor ótimo, foi conduzida uma busca em grade sobre o conjunto $\{0{,}001;\ 0{,}005;\ 0{,}01;\ 0{,}025;\ 0{,}05;\ 0{,}1;\ 0{,}3;\ 0{,}5;\ 1{,}0\}$. A busca foi realizada com o estimador `stan-map` (otimização por máxima a posteriori, computacionalmente leve em relação ao MCMC) para viabilizar a varredura no mesmo *holdout* interno 2018–2019 utilizado para o GAM, garantindo que o conjunto de teste não fosse consultado nessa etapa. O valor com menor MAE no *holdout* foi selecionado para o ajuste final.

5.7.3 Ajuste Final e Decomposição Estrutural

Definidas as variáveis selecionadas e o valor ótimo de `sigma_prior`, o BSTS foi ajustado com o estimador `stan-map`. Uma avaliação adicional com MCMC reforçado (1500 *warmup* $\times$ 1500 amostras $\times$ 4 cadeias) produziu desempenho inferior no conjunto de teste em comparação ao MAP, sendo descartada. O estimador MAP demonstrou-se mais estável para este conjunto de dados, possivelmente em razão da alta regularização imposta pelo en-

colhimento bayesiano e do baixo sinal explicativo nos retornos diários. Além disso, o EMBI+ (ΔEMBI+), excluído pela análise de intervalos de credibilidade na parametrização uniforme, foi reincorporado ao modelo final com um *prior* heterogêneo, dez vezes maior do que o dos demais regressores, permitindo que seu efeito se manifestasse sem ser suprimido pelo encolhimento comum. Esse ajuste resultou em ganho expressivo de R^2 no conjunto de teste. Após o ajuste final, a previsão *out-of-sample* foi obtida com o estimador MAP, que fornece apenas previsão pontual sem intervalos de credibilidade, e o método `predict(decompose=True)` separou a previsão em tendência, sazonalidade e regressão.

5.8 Configuração e Otimização do Modelo Causal Forest

A arquitetura modular do trabalho orientou deliberadamente a especificação do espaço de covariáveis de cada modelo. Os modelos anteriores — GAM e BSTS — foram especificados exclusivamente com variáveis macroeconômicas domésticas (Selic, IPCA, PIB, EMBI+ e expectativas de inflação). Essa escolha se justifica pela necessidade de isolar e mapear com precisão os canais internos de transmissão e as não linearidades características da economia brasileira, sem a interferência de choques de volatilidade global, que competem pela variância do retorno diário e podem mascarar o sinal emitido pelas variáveis locais. Como o sinal explicável em retornos diários é estruturalmente baixo, manter esses dois modelos restritos ao conjunto doméstico preserva sua parcimônia e reduz o risco de sobreajuste e de multicolinearidade que variáveis globais altamente voláteis poderiam introduzir.

Como complementação analítica, o modelo Causal Forest demanda uma expansão controlada do cenário informacional. O objetivo desta etapa é estimar o efeito causal de um choque cambial exógeno sobre o Ibovespa e reduzir o viés de variável omitida proveniente do contexto internacional. Em ambientes observacionais complexos, flutuações cambiais e quedas no índice acionário doméstico podem ser desencadeadas conjuntamente por episódios de aversão ao risco global, de modo que ignorar esse contexto compromete a validade da identificação causal. Por essa razão, decidiu-se pela inclusão das variáveis VIX, S&P 500 e preço do petróleo exclusivamente no *framework* do Causal Forest. Essa estratégia permite ao algoritmo discernir se a heterogeneidade do efeito causal sobre o Ibovespa é decorrente de vulnerabilidades macroeconômicas internas ou de movimentos generalizados de fuga de capital global (*fly to safety*). Do ponto de vista técnico, a Causal Forest lida naturalmente com alta dimensionalidade por meio de partições recursivas regularizadas, o que viabiliza a ampliação do vetor de covariáveis sem o risco de instabilidade estrutural que modelos aditivos, como o GAM, enfrentariam ao incorporar variáveis adicionais sem redesenho de toda a estrutura de suavização.

O modelo Causal Forest foi estimado por meio da implementação `CausalForestDML` da biblioteca `econml`, que combina o arcabouço de Florestas Aleatórias Generalizadas de Athey, Tibshirani e Wager (2019) com o estimador de Double Machine Learning de Cher-

nozhukov et al. (2018a). A estrutura causal adotada define Y como o retorno logarítmico diário do Ibovespa (`br_ibov_ret_log`), T como a variável de tratamento binária que indica dias de choque cambial e X como o vetor de covariáveis macroeconômicas.

A definição do tratamento seguiu critério idêntico ao adotado nos demais modelos quanto à ausência de contaminação de dados futuros. A variável `T_choque_dolar` assume valor 1 nos dias em que a variação absoluta do câmbio supera o percentil 75 da distribuição calculada *exclusivamente* sobre o conjunto de treino (2001–2019), com limiar resultante de 0,0229. Essa restrição ao período de treino evita que a distribuição do conjunto de teste contamine a definição do tratamento, o que introduziria leakage temporal na identificação causal.

A variável `br_dolar_diff` foi excluída do vetor de covariáveis porque o tratamento T é função determinística dela — incluí-la violaria a condição de positividade (sobreposição), tornando a identificação do efeito causal inválida. O vetor de covariáveis final compreende oito variáveis: `br_selic_diff`, `br_ipca`, `br_pib_ret_log`, `ipca_expectativa_diff`, `embi_brasil_diff`, `vix_ret_log`, `sp500_ret_log` e `petroleo_ret_log`. Os contratos futuros de Brent crude (`BZ=F`) estão disponíveis no Yahoo Finance apenas a partir de julho de 2007; para o período anterior (2001–2007), o log-retorno do petróleo foi imputado como zero, correspondendo ao retorno neutro — ausência de sinal global, não ausência de dado. Essa imputação, contudo, carrega um risco específico: ao fixar o retorno em zero sistematicamente por quase seis anos, o modelo pode interpretar o período como uma sequência de variações nulas de preço, gerando um choque deflacionário artificial na covariável em relação aos períodos com dados reais. Para versões futuras do trabalho, a consulta ao Ipeadata — que disponibiliza séries de preço de petróleo desde datas anteriores a 2001 — representa um caminho de baixo custo para eliminar essa imprecisão e verificar se a covariável global para esse período modifica as conclusões sobre a heterogeneidade do CATE nos primeiros anos da janela de treino.

A seleção de hiperparâmetros foi conduzida por busca aleatória com $N = 150$ configurações, avaliadas sobre o *holdout* interno 2018–2019 pelo critério de R-loss causal, critério derivado do R-learner de Nie e Wager (2021), que quantifica o ajuste aos pseudo-desfechos $\tilde{Y}/\tilde{T}$ sem exigir conhecimento do efeito causal verdadeiro. Entre as 150 configurações, o modelo que minimizou o R-loss no *holdout* após filtragem por sanidade (R^2 preditivo $\geq$ mediana do top-20 $-$ 0,02) apresentou os seguintes parâmetros: `n_estimators` = 2504, `min_samples_leaf` = 76, `max_depth` = 10, `max_features` = `None`, `min_balancedness_tol` = 0,3367, `subforest_size` = 8. Os modelos de nuisance para o desfecho e para o tratamento foram configurados como `GradientBoostingRegressor` e `GradientBoostingClassifier`, respectivamente, ambos com 100 estimadores, profundidade máxima 2 e taxa de aprendizado 0,03. O R-loss causal no *holdout* para a configuração selecionada foi 0,000132.

A robustez dessa configuração foi avaliada comparando-se os limiares $p70$ (0,0197),

$p75$ (0,0229) e $p80$ (0,0270). Em todos os três cortes, o efeito causal médio não foi estatisticamente distinto de zero e a heterogeneidade do efeito condicional foi detectável pelo Best Linear Predictor. O limiar $p75$ produziu o melhor R^2 preditivo fora da amostra (0,4028 com oito covariáveis) e é coerente com o uso do quantil 75 como corte-padrão na literatura de volatilidade cambial, sendo adotado como configuração principal. Os resultados comparativos dos três limiares são apresentados na Tabela 9.

5.8.1 Hipóteses de Identificação Causal

A estimação de efeitos causais em dados observacionais requer que um conjunto de premissas, formalizadas no arcabouço de resultados potenciais de RUBIN (1974) e desenvolvidas por ROSENBAUM; RUBIN (1983), seja ao menos parcialmente atendido. Esta subseção discute cada uma dessas premissas no contexto específico do desenho adotado, reconhecendo abertamente onde são satisfeitas, onde permanecem como aproximações e onde constituem simplificações declaradas do modelo.

Seleção nas observáveis (ignorabilidade / *unconfoundedness*). Essa premissa exige que, condicional às covariáveis observadas, a atribuição do tratamento seja independente dos resultados potenciais — isto é, que não existam variáveis omitidas que determinem simultaneamente a ocorrência do choque cambial e o retorno do Ibovespa. O vetor de covariáveis adotado é informacionalmente rico, incorporando tanto variáveis domésticas (Selic, IPCA, PIB, risco-país) quanto variáveis de risco global (VIX, S&P 500 e petróleo), precisamente para reduzir o viés proveniente de confundidores internacionais. Mesmo assim, o vetor é necessariamente incompleto: choques políticos internos e externos de natureza não antecipada e variáveis de sentimento de mercado captadas em redes sociais representam canais omitidos potencialmente relevantes. BOLLEN; MAO; ZENG (2011) demonstraram empiricamente que medidas de humor extraídas de publicações no Twitter antecipam variações em índices acionários americanos, o que sugere que variáveis de sentimento podem carregar sinal preditivo sobre retornos que os fundamentalistas macroeconômicos aqui utilizados não cobrem integralmente. O Double Machine Learning do `CausalForestDML` mitiga parte desse viés ao modelar o desfecho e o tratamento de forma flexível antes de estimar o CATE residual, mas a premissa de ignorabilidade permanece como hipótese de identificação, não como resultado verificável.

Suporte comum (*positividade*). Para que o efeito causal seja identificável em cada ponto do suporte das covariáveis, toda combinação observada de X deve apresentar probabilidade positiva de exposição ao tratamento ($0 < P(T = 1 \mid X) < 1$). A série de mais de duas décadas utilizada neste trabalho, cobrindo múltiplos regimes econômicos — ciclos de alta e queda de juros, crises cambiais, recessão técnica e choque pandêmico —, oferece variação ampla e diversificada do tratamento ao longo do tempo, tornando o suporte comum plausível em termos qualitativos. Cabe reconhecer, contudo, que não foi conduzido um teste formal de sobreposição (*overlap*) sobre as distribuições das covariáveis, e que a assimetria de prevalên-

cia entre treino (25,0% de dias de choque) e teste (55,9%) indica que o regime do período de avaliação difere do período de estimação de forma não trivial, o que impõe cautela adicional na extrapolação das estimativas para regimes distintos.

SUTVA — Ausência de interferência (*no spillover*). Essa premissa estabelece que o resultado observado na unidade t deve depender exclusivamente do tratamento recebido por t, sem transbordamento temporal para unidades adjacentes. Em séries financeiras diárias, essa premissa é particularmente difícil de satisfazer: um choque cambial intenso em determinado pregão pode alterar as expectativas dos investidores e suas decisões de alocação nos pregões subsequentes, criando persistência que contamina os resultados de dias vizinhos. As transformações de log-retorno e primeiras diferenças reduzem a dependência temporal de longo prazo, mas não eliminam a persistência de curto prazo documentada pelos testes de Ljung-Box sobre a série-alvo. Este trabalho declara essa tensão explicitamente, sem propor um instrumento para resolvê-la, reconhecendo-a como uma limitação estrutural do desenho em granularidade diária.

SUTVA — Consistência (ausência de múltiplas versões do tratamento). Essa premissa exige que o tratamento seja uniforme para todas as unidades que o recebem, ou seja, que $T = 1$ descreva o mesmo mecanismo de intervenção em todos os casos. No presente trabalho, o tratamento binário (variação cambial acima do percentil 75) agrega origens heterogêneas: um choque decorrente de uma decisão de política monetária, uma crise política doméstica, uma saída global de capitais ou uma deterioração fiscal não constituem, do ponto de vista do mecanismo de transmissão, o mesmo tratamento, embora todos ativem a variável indicadora $T = 1$. Essa agregação é uma simplificação declarada do desenho adotado, não uma premissa validada, e implica que o CATE estimado deve ser interpretado como o efeito médio sobre o conjunto heterogêneo de choques cambiais superiores ao limiar, e não como o efeito de um tipo específico de choque cambial.

6 Revisão Bibliográfica

Em estudo conduzido por SCHAFFER; DOBBINS; PEARSON (2021), os autores demonstram como o uso de ARIMA pode superar limitações do método tradicional de regressão segmentada na avaliação de intervenções em séries temporais interrompidas (Interrupted Time Series – ITS). O trabalho ilustra, por meio de dados reais de dispensação de medicamentos na Austrália, que o modelo ARIMA foi capaz de capturar adequadamente os efeitos de uma política pública de saúde, mesmo diante de padrões sazonais e estruturas autocorrelacionadas dos dados.

De forma complementar ao ARIMA, mas com foco na modelagem explicativa multivariada, a regressão linear com estimador de Mínimos Quadrados Ordinários (MQO) permanece como um dos métodos mais tradicionais e amplamente utilizados na econometria, principalmente por sua simplicidade, interpretabilidade e capacidade de estimar relações lineares entre variáveis econômicas. No estudo de HOANG; WIEGRATZ (2022), os autores compararam o desempenho do MQO com algoritmos de aprendizado de máquina na previsão de preços de imóveis residenciais na Alemanha. Os resultados mostraram que, embora o MQO forneça uma linha de base interpretável com métricas estatísticas úteis (como t-valores e p-valores), seus erros de previsão foram significativamente maiores, especialmente nas faixas superiores de preço, em relação aos métodos baseados em aprendizado de máquina, como boosted regression trees. A análise evidencia que, apesar de sua relevância teórica e interpretativa, o MQO apresenta limitações importantes em cenários com alto número de variáveis ou presença de relações não lineares.

No estudo de ZHANG (2025), o autor destaca que dados financeiros, especialmente em contextos de alta volatilidade, frequentemente exibem padrões não lineares e relações dinâmicas influenciadas por múltiplos fatores exógenos, como choques macroeconômicos, comportamento de investidores e incerteza global. Nesse cenário, os Modelos Aditivos Generalizados (GAMs) surgem como uma alternativa poderosa por permitirem maior flexibilidade na modelagem das relações entre variáveis, ao decompor efeitos não lineares por meio de funções suavizadas. Evidências empíricas no estudo demonstraram que o uso de GAMs resultou em melhorias superiores a 10% na previsão de volatilidade em comparação com abordagens lineares, sobretudo em momentos de estresse no mercado. Também foi observado que GAMs se mostraram eficazes ao modelar padrões de volatilidade em função de variáveis macroeconômicas, mesmo em ambientes marcados por rupturas estruturais.

Seguindo a mesma linha de modelos que valorizam flexibilidade e estrutura dinâmica, em estudo recente, QIU; JAMMALAMADAKA; NING (2020) propôs uma extensão multivariada do modelo BSTS tradicional, capaz de capturar estruturas de associação entre múltiplas

séries-alvo e realizar seleção automática de variáveis por meio do framework “spike and slab”. Os resultados empíricos mostraram que o modelo superou modelos benchmark como ARIMA em previsões de curto e médio prazo, especialmente quando há correlação entre os erros das séries-alvo. Tais resultados reforçam o potencial do BSTS para análise de mercados financeiros, onde múltiplos indicadores atuam simultaneamente sobre séries como o Ibovespa, e onde a incorporação de incerteza e estrutura dinâmica é essencial.

O método Causal Forest, proposto por GULEN; JENS; PAGE (2024), representa um avanço na estimação de efeitos causais heterogêneos em dados observacionais, especialmente quando a aleatorização não é viável. Em comparação com MQO e RDD, o Causal Forest demonstrou maior robustez a vieses e maior capacidade de generalização, estimando efeitos condicionais de tratamento (CATE) com menor viés. A aplicação empírica mostrou que, mesmo com efeitos médios pequenos, o modelo foi capaz de identificar subgrupos com respostas causais significativas, evidenciando que a heterogeneidade nos efeitos é crucial para entender fenômenos econômicos complexos. Assim, o Causal Forest se posiciona como um estimador flexível e valioso na análise causal moderna, equilibrando validade interna e externa.

7 Resultados Parciais

Este capítulo apresenta os resultados obtidos ao longo do trabalho. A primeira seção consolida a linha de base, com o tratamento dos dados, os testes de estacionariedade e a estimação dos modelos econométricos clássicos (ARIMA e MQO). Em seguida, são apresentados os resultados *out-of-sample* dos modelos de IA interpretável (GAM e BSTS), encerrando-se com uma síntese comparativa entre os modelos. As escolhas de configuração de cada modelo — como a inclusão da *feature* autorregressiva `ibov_lag1` e o *prior* heterogêneo para o ΔEMBI+ no BSTS — decorrem da análise exploratória direcionada descrita na Seção 5.4.

7.1 Linha de Base

A análise preliminar das séries macroeconômicas e financeiras em seus níveis originais indicou correlações elevadas e estatisticamente enganosas. Por exemplo, a correlação entre o PIB e o Ibovespa foi de aproximadamente 0,92, valor que reflete mais uma tendência comum de longo prazo do que uma relação causal genuína.

Para evitar regressões espúrias, todas as séries foram transformadas com base em sua natureza econômica, como visto na Tabela 2.

Variável	**Transformação Aplicada**
Ibovespa	Retorno logarítmico
PIB	Retorno logarítmico
Câmbio (Dólar)	Primeira diferença
Taxa Selic	Primeira diferença
Risco-País (EMBI+)	Primeira diferença
IPCA (Inflação ao consumidor)	Nenhuma (série já estacionária)

Tabela 2 – Transformações aplicadas às variáveis da base de dados

Após essas transformações, um novo mapa de calor foi construído, revelando correlações mais consistentes com a teoria econômica. Destaca-se a correlação negativa entre a variação do dólar e o retorno do Ibovespa ($\rho = -0{,}34$), comportamento esperado em períodos de aversão a risco (Figura 1).

A validade estatística dos modelos de séries temporais exige que as variáveis sejam estacionárias. Foram aplicados os testes ADF (Augmented Dickey-Fuller) e KPSS (Kwiatkowski-Phillips-Schmidt-Shin) tanto nas séries originais quanto nas transformadas. A maioria das séries em nível apresentou sinais claros de não estacionariedade (p-valor alto no ADF, baixo no KPSS). Após a transformação, todas as variáveis mostraram-se estacionárias, com p-valores do ADF próximos de zero e p-valores do KPSS acima de 0,05.

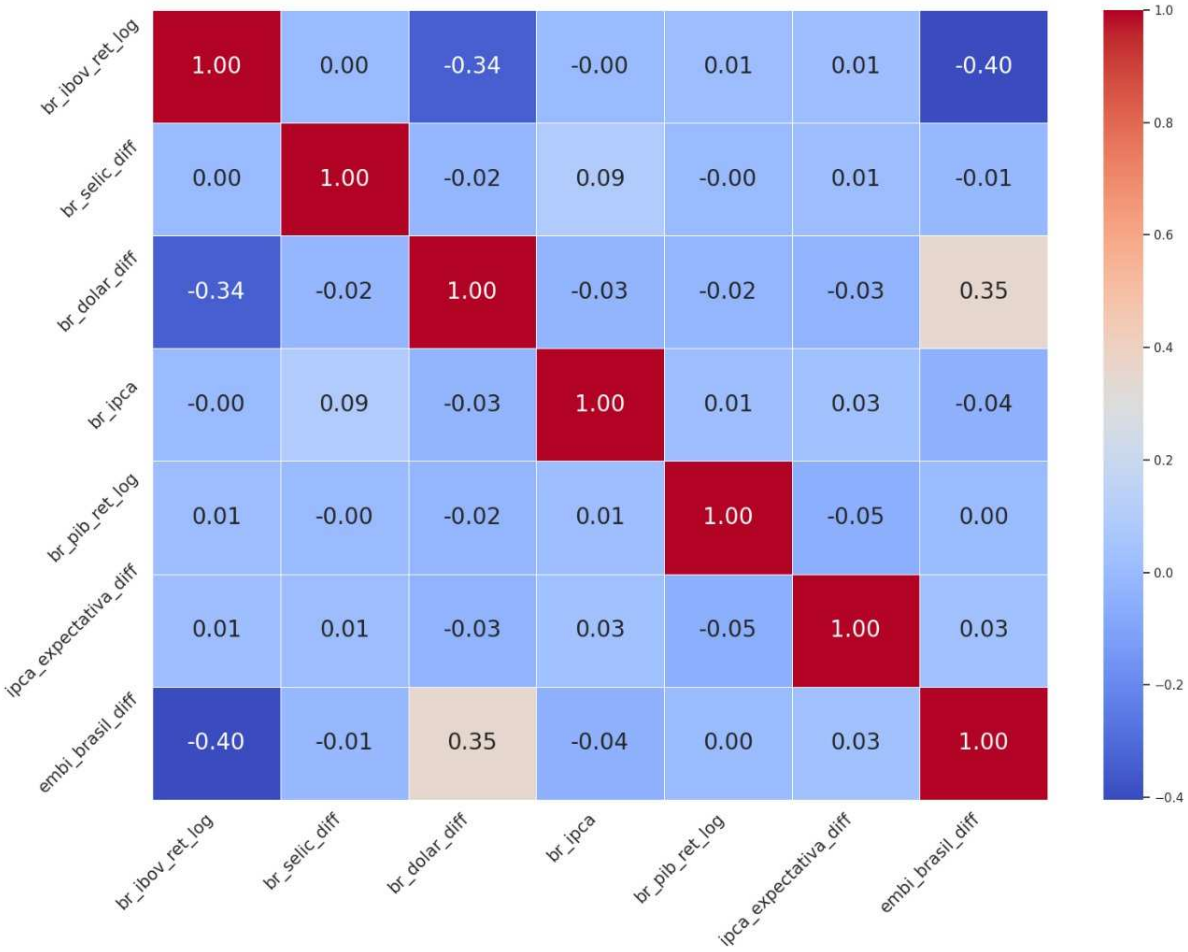


Figura 1 – Mapa de Calor - Correlação das Variáveis Transformadas (Fonte: Autor)

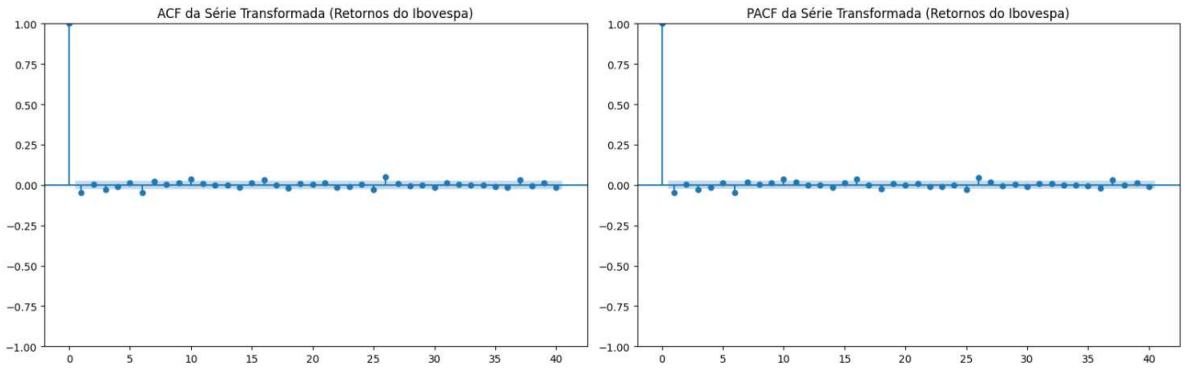


Figura 2 – Gráficos ACF e PACF da série transformada (Fonte: Autor)

Esses resultados garantem a adequação dos dados para modelagens posteriores, evitando vieses nas inferências.

Um modelo ARIMA foi ajustado à série de retornos logarítmicos do Ibovespa. Com base na análise de ACF/PACF (Figura 2) e na seleção automática via critério AIC, foi identificado o modelo ARIMA(4, 0, 3). O teste de Ljung-Box apresentou p-valor de 0,29, indicando

que não há autocorrelação significativa nos resíduos — o que sugere que o modelo conseguiu capturar adequadamente a dinâmica interna da série.

Este resultado estabelece um benchmark univariado, baseado apenas no comportamento passado do índice.

Em seguida, foi estimado um modelo de regressão linear múltipla com os retornos do Ibovespa como variável dependente e as variáveis transformadas como preditoras. Observou-se que **R^2 = 0,209**. Embora o valor seja considerado razoável em contextos de alta volatilidade como o mercado financeiro, ele também evidencia uma limitação importante do modelo MQO: sua baixa capacidade explicativa frente à complexidade das relações econômicas envolvidas. Além disso, o MQO assume linearidade, homocedasticidade e ausência de interações complexas entre variáveis — suposições muitas vezes violadas em séries financeiras. Essas restrições reforçam a necessidade de empregar modelos mais flexíveis e robustos, como GAM, BSTS e Causal Forest, que são capazes de capturar não linearidades, efeitos dinâmicos e relações causais heterogêneas com maior precisão e interpretabilidade. Identificação de dois preditores estatisticamente significativos: variação do dólar, com impacto negativo e variação do risco-país (EMBI+), também com impacto negativo. Os testes diagnósticos indicaram ausência de multicolinearidade (VIF baixo), como visto na Tabela 3, mas rejeição das hipóteses de normalidade e homocedasticidade dos resíduos.

Variável	**VIF**
Constante (intercepto do modelo)	2,8216
Variação da taxa Selic	1,0091
Variação de câmbio dólar (venda)	1,1439
Índice de Preços ao Consumidor Amplo (IPCA)	1,0119
Retorno logarítmico do PIB	1,0039
Variação da expectativa de inflação (IPCA esperado)	1,0076
Variação do risco-país (EMBI+ Brasil)	1,1441

Tabela 3 – Fatores de Inflação da Variância (VIF) para as variáveis explicativas do MQO

Para uma avaliação consolidada do desempenho dos modelos da linha de base, foram calculadas, além do R^2, as métricas MAE (Erro Médio Absoluto) e RMSE (Raiz do Erro Quadrático Médio). O MAE mede o desvio médio absoluto entre os valores preditos e os observados, expressando o erro em unidades da própria variável. O RMSE, por sua vez, penaliza de forma quadrática os erros maiores, sendo mais sensível a eventos extremos — característica especialmente relevante em séries financeiras sujeitas a choques e períodos de alta volatilidade. A Tabela 4 apresenta o comparativo *in-sample* entre os modelos estimados, incluindo o ajuste preliminar do GAM realizado sobre o conjunto completo dos dados.

Modelo	**R²**	**MAE**	**RMSE**
ARIMA(4, 0, 3)	—	0,012225	0,017085
OLS / MQO	0,2086	0,011093	0,015239
GAM	0,2946	0,010758	0,014398

Tabela 4 – Métricas de avaliação dos modelos estimados — linha de base *in-sample* (conjunto completo)

7.2 Resultados do Modelo GAM

A linha de base indicou que o GAM já produz ganho explicativo *in-sample* relevante em relação ao MQO (R² = 0,2946 contra 0,2086). Esta seção apresenta a avaliação *out-of-sample* do GAM, conduzida sobre o conjunto de teste (2020–2024) com o procedimento de otimização descrito na Seção 5.6.

A Tabela 5 apresenta os resultados da busca pelo número ótimo de splines, avaliando R² no conjunto de treino e MAE no conjunto de teste para cada valor do grid.

$n_splines$	**R²_ajuste**	**MAE_holdout**
5	0,2098	0,008993
10	**0,2779**	**0,008857**
15	0,2901	0,008879
20	0,2982	0,008891
25	0,3036	0,008943

Tabela 5 – Busca pelo número ótimo de splines no GAM: R² no subconjunto de ajuste (2001–2017) e MAE no *holdout* 2018–2019 (negrito = configuração selecionada)

O valor $n^* = 10$ produziu o menor MAE no *holdout* 2018–2019, sendo selecionado para o modelo final. Observa-se que valores crescentes de $n_splines$ continuam elevando o R² de ajuste, mas deterioram o desempenho no *holdout*, padrão característico de sobreajuste que justifica o uso de uma partição de validação independente como critério de seleção.

Em seguida, foi conduzida a análise do tipo de termo por variável. A Tabela 6 apresenta o MAE no *holdout* 2018–2019 para cada variável sob a representação linear $l(\cdot)$ e suavizada $s(\cdot)$, bem como o ganho não linear ΔMAE_j definido na Equação 5.3.

Variável	**MAE com $l(\cdot)$**	**MAE com $s(\cdot)$**	**ΔMAE**	**Tipo**
ΔEMBI+ (Risco-País)	0,009129	0,008857	+0,000272	$s(\cdot)$
Retorno PIB	0,008861	0,008857	+0,000004	$s(\cdot)$
ΔSelic	0,008848	0,008857	−0,000009	$l(\cdot)$
ΔExpectativa IPCA	0,008844	0,008857	−0,000013	$l(\cdot)$
IPCA	0,008818	0,008857	−0,000039	$l(\cdot)$
ΔCâmbio (Dólar)	0,008809	0,008857	−0,000048	$l(\cdot)$

Tabela 6 – Análise *smooth* vs. linear por variável com critério no *holdout* 2018–2019: $\Delta\text{MAE}_j > 0$ indica ganho não linear

Com o critério de *holdout*, apenas o risco-país (ΔEMBI+) apresentou ganho não linear expressivo ($\Delta\text{MAE} = +0{,}000272$). O câmbio, que no critério de teste antigo aparecia como segundo maior beneficiário, apresentou delta negativo ($-0{,}000048$), indicando que o sinal era espúrio. Um experimento formal de aplicação da regra s/l derivada do *holdout* (G2) foi avaliado no conjunto de teste e resultou em queda de R^2 para 0,2809, abaixo do *baseline* de 0,2938, sendo rejeitado. O modelo final mantém, portanto, todos os termos como $s(\cdot)$, preservando a flexibilidade não linear sem introduzir restrições baseadas em generalização da seleção em si.

Além da seleção de termos, dois ajustes adicionais foram aceitos pelo critério A/B. O primeiro (G4) substituiu o IPCA em nível pela sua primeira diferença, corrigindo a inconsistência estocástica no vetor de preditores. O segundo (G8) adicionou o retorno do Ibovespa no pregão anterior (`ibov_lag1`) como *feature*, capturando autocorrelação de curto prazo não explicada pelos indicadores macroeconômicos. Com essas melhorias, o GAM final atingiu R^2 de 0,3045 no conjunto de teste e MAE de 0,009997, com R^2 de 0,2946 no treino (2001–2019), indicando ausência de sobreajuste e boa capacidade de generalização.

Os gráficos de dependência parcial (PDPs) estimados para o modelo GAM final permitem visualizar o efeito marginal de cada variável sobre os retornos do Ibovespa, mantendo as demais constantes. A Figura 3 apresenta os PDPs das sete variáveis preditoras, com a faixa sombreada representando o intervalo de confiança de 95%. PDPs mostram como a predição média do modelo varia ao longo da distribuição de uma variável, revelando não linearidades, assimetrias e efeitos de saturação (FRIEDMAN, 2001).

Os resultados revelam padrões não lineares com interpretação econômica direta. A variação do câmbio (ΔCâmbio) apresenta a relação não linear mais pronunciada do modelo. Depreciações cambiais exercem efeito negativo desde magnitudes moderadas, e esse efeito se intensifica em episódios de grande desvalorização, evidenciando assimetria: o impacto negativo de uma desvalorização é substancialmente maior em módulo do que o efeito positivo de uma apreciação equivalente. Esse comportamento é coerente com a hipótese de fuga de capitais em momentos de estresse cambial, em que choques de desvalorização elevam a percepção de risco de forma não proporcional.

A variação do risco-país (ΔEMBI+) exibe relação negativa e não linear, com saturação parcial em choques extremos. Aumentos no risco-país reduzem os retornos do Ibovespa de forma consistente, mas a curva se torna progressivamente mais plana para variações muito elevadas (acima de +150 pontos), sugerindo que o mercado incorpora parcialmente esses choques de forma antecipada. Reduções no risco-país (valores negativos) têm efeito positivo relevante. Esse padrão seria invisível ao modelo OLS, cujo coeficiente captura apenas o efeito médio ao longo de toda a distribuição.

O IPCA apresenta efeito modesto e leve forma de U invertido. Inflação em patamares moderados (0,5–1,5% ao mês) tem pequeno efeito positivo sobre os retornos, possivelmente refletindo correlação com aquecimento econômico, e para valores muito elevados o efeito tende

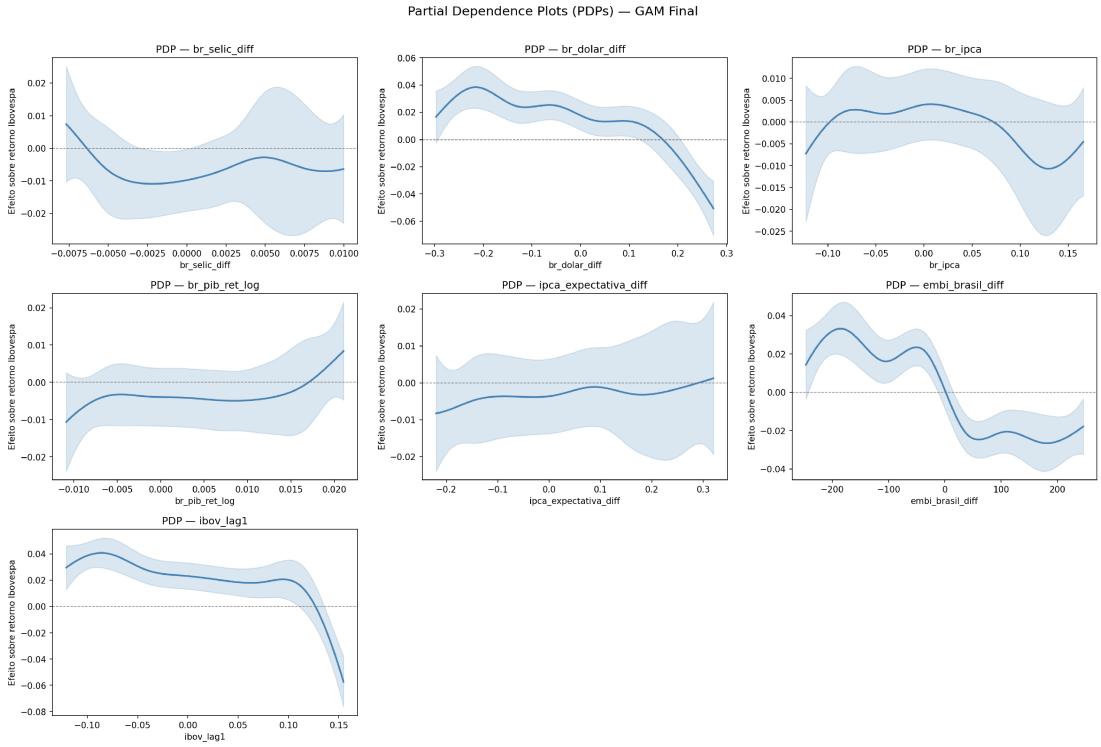


Figura 3 – Partial Dependence Plots (PDPs) do GAM final (G4+G8): efeito marginal das sete variáveis preditoras sobre o retorno logarítmico do Ibovespa, incluindo IPCA em primeiras diferenças e *feature* autorregressiva `ibov_lag1` (Fonte: Autor)

a se inverter. A banda de confiança larga indica que o IPCA possui baixa importância individual no horizonte diário. O retorno do PIB exibe relação positiva e aproximadamente linear, compatível com a teoria de que crescimento econômico acompanha valorização do mercado acionário, e a ausência de ganho não linear nessa variável, identificada na etapa de otimização (Seção 5.6), é confirmada visualmente pela forma quase linear do PDP.

A variação da Selic (ΔSelic) e ΔExpectativa IPCA apresentam efeitos marginais reduzidos e bandas de confiança largas. No horizonte diário, variações marginais na Selic já são tipicamente antecipadas pelo mercado, o que é consistente com a hipótese de eficiência informacional na forma semi-forte. Por fim, o retorno do Ibovespa com defasagem 1 (`ibov_lag1`) apresenta efeito positivo e aproximadamente linear, refletindo continuação de tendência de curtíssimo prazo. O ganho preditivo foi confirmado pelo critério A/B, com melhora de 1,6% no MAE e 0,0101 no R^2_teste em relação ao *baseline*, o que justifica sua inclusão no modelo mesmo sendo uma variável defasada da própria série-alvo, e não um preditor macroeconômico externo.

Os PDPs reforçam, dessa forma, que risco-país e câmbio são os canais dominantes de transmissão macroeconômica para o mercado acionário brasileiro, com dinâmicas não lineares que o modelo OLS não consegue capturar. O efeito do risco-país é assimétrico com saturação em choques extremos, enquanto o câmbio exerce influência negativa robusta. Esses padrões

ilustram o ganho de transparência que modelos aditivos como o GAM oferecem em relação a abordagens puramente lineares.

7.3 Resultados do Modelo BSTS

A estimação do modelo Bayesian Structural Time Series (BSTS) seguiu o procedimento descrito na Seção 5.7. Os resultados são apresentados em três etapas: seleção de variáveis a partir das distribuições posteriores, otimização do hiperparâmetro `sigma_prior` e avaliação *out-of-sample* do modelo final, incluindo a decomposição estrutural da série.

7.3.1 Seleção Bayesiana de Variáveis

A primeira estimação foi realizada com todas as seis covariáveis e `sigma_prior` padrão (0,5), gerando $4 \times 500 = 2000$ amostras posteriores para cada coeficiente de regressão. A Tabela 7 sumariza as estatísticas posteriores e o critério de seleção.

Variável	**Média**	**Desvio**	**IC 90% inf.**	**IC 90% sup.**	**Selecionada**
ΔSelic	$-0{,}0206$	0,0035	$-0{,}0236$	$-0{,}0151$	Sim
ΔCâmbio (Dólar)	$-0{,}0249$	0,0016	$-0{,}0264$	$-0{,}0223$	Sim
IPCA	$+0{,}1583$	0,0029	$+0{,}1540$	$+0{,}1618$	Sim
Retorno PIB	$+0{,}0759$	0,0012	$+0{,}0744$	$+0{,}0775$	Sim
ΔExpectativa IPCA	$-0{,}0465$	0,0029	$-0{,}0502$	$-0{,}0433$	Sim
ΔEMBI+ (Risco-País)	$+0{,}0076$	0,0155	$-0{,}0065$	$+0{,}0344$	Não

Tabela 7 – Estatísticas posteriores dos coeficientes do BSTS completo: média, desvio padrão e intervalo de credibilidade a 90%. A variável é selecionada quando o IC 90% não cruza zero.

Cinco das seis variáveis apresentaram intervalos de credibilidade a 90% inteiramente fora do zero, sendo inicialmente selecionadas. A única exclusão foi a variação do risco-país (ΔEMBI+), cuja distribuição posterior cobriu valores positivos e negativos (IC 90% $= [-0{,}0065;\ +0{,}0344]$), com probabilidade de inclusão de apenas 0,59. Esse resultado contrasta com a evidência consistente de relevância do EMBI+ identificada nos PDPs do GAM. Uma interpretação plausível é que, na parametrização com `sigma_prior` uniforme e padrão, parte do efeito do EMBI+ é absorvida por componentes estruturais (tendência e sazonalidade) e por sua correlação parcial com o câmbio, reduzindo o sinal residual atribuído à variável.

Diante dessa hipótese, o ΔEMBI+ foi reincorporado ao modelo final com um *prior* heterogêneo, dez vezes mais amplo do que o dos demais regressores, permitindo que seu coeficiente se manifestasse sem ser suprimido pelo encolhimento uniforme. Cabe deixar explícito que essa decisão não foi tomada de forma *ad hoc* sobre os resultados do BSTS, mas seguiu diretamente a evidência cruzada do GAM, estimado na etapa anterior: os PDPs do GAM já haviam identificado o ΔEMBI+ como o canal com maior ganho não linear sobre os retornos do Ibovespa, o que motivou documentadamente o teste de um *prior* mais informativo para esse regressor no passo

seguinte — a sequência de estimação adotada no trabalho torna esse encadeamento rastreável. Essa escolha é, adicionalmente, consistente com o achado da análise exploratória (Seção 5.4), que identificou no ΔEMBI+ desvio padrão aproximadamente 500 vezes maior do que o das demais covariáveis, tornando-o particularmente vulnerável ao encolhimento uniforme. Esse ajuste (experimento B7) resultou em elevação expressiva do R^2_teste de 0,1401 para 0,2436, sendo o principal responsável pelo ganho do BSTS final em relação ao *baseline* operacional.

A Figura 4 ilustra as distribuições posteriores dos seis coeficientes, com os intervalos de credibilidade a 90% (laranja) e 95% (vermelho) destacados.

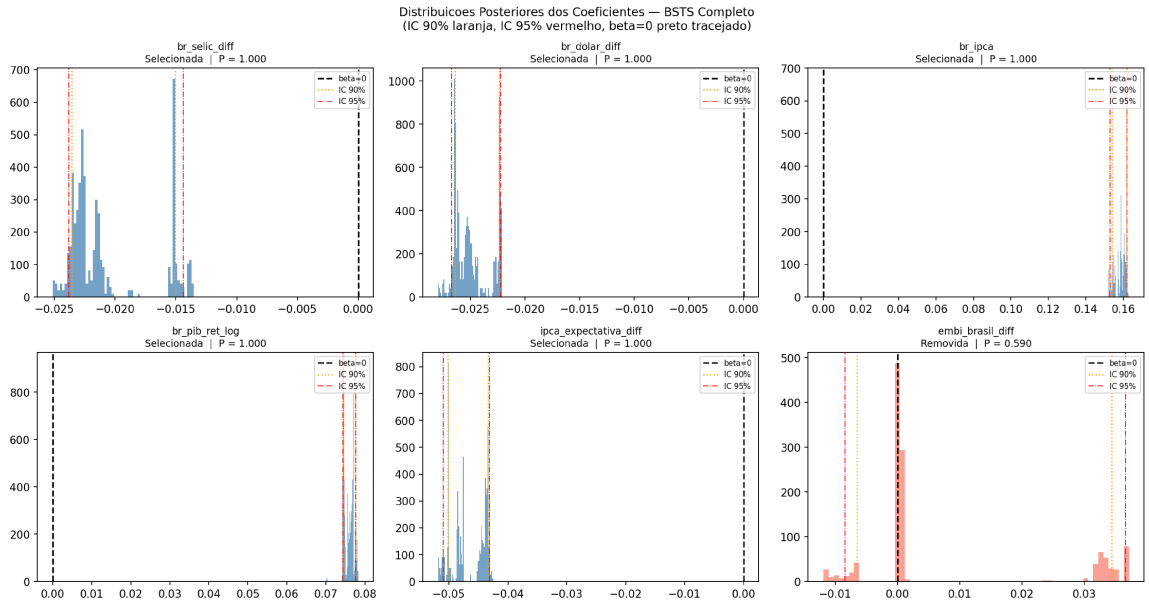


Figura 4 – Distribuições posteriores dos coeficientes do BSTS completo. Variáveis cujo IC 90% não cruza zero (azul) são selecionadas; a variável removida (salmão) corresponde ao ΔEMBI+ (Fonte: Autor)

7.3.2 Otimização do Encolhimento Bayesiano

Definidas as cinco variáveis inicialmente selecionadas, a etapa seguinte consistiu na busca em grade do valor ótimo de `sigma_prior`, conforme descrito na Seção 5.7. A grade foi expandida para cobrir valores de regularização mais forte ($\sigma \geq 0{,}001$), avaliada sobre o mesmo *holdout* 2018–2019 utilizado para o GAM. A Tabela 8 apresenta os resultados.

O valor $\sigma^* = 0{,}01$ produziu o menor MAE no *holdout*, indicando que um encolhimento bayesiano agressivo, com os coeficientes fortemente concentrados em torno de zero, é benéfico nesse contexto. Esse resultado é coerente com a característica de retornos diários, em que o sinal explicativo é tipicamente fraco e modelos pouco regularizados tendem a sobreajustar ruído. A Figura 5 mostra a curva de MAE e RMSE em função de `sigma_prior` em escala logarítmica, revelando que o mínimo se encontra em valores mais baixos do que a grade original (com máximo de $0{,}05$) capturava.

`sigma_prior`	MAE_holdout	RMSE_holdout
0,001	0,010029	0,012891
0,005	0,009880	0,012739
0,01	**0,009497**	**0,012188**
0,025	0,009506	0,012197
0,05	0,009576	0,012248
0,10	0,009601	0,012309
0,30	0,009622	0,012355
0,50	0,009515	0,012234
1,00	0,009624	0,012356

Tabela 8 – Busca em grade para `sigma_prior`: MAE e RMSE no *holdout* 2018–2019 (negrito = configuração selecionada).

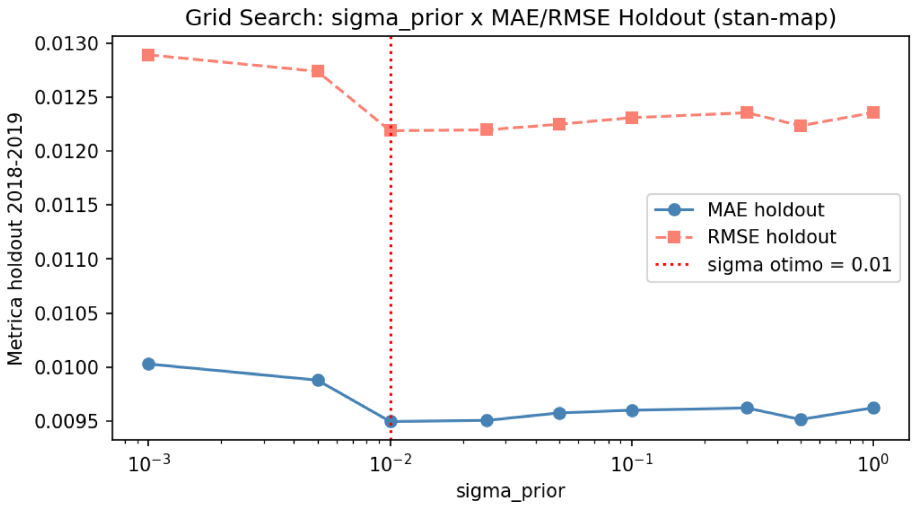


Figura 5 – Curva de MAE e RMSE no *holdout* 2018–2019 em função de `sigma_prior` (escala logarítmica). O mínimo ocorre em $\sigma^* = 0{,}01$ (Fonte: Autor)

7.3.3 Avaliação Out-of-Sample e Decomposição Estrutural

O modelo BSTS final, ajustado com todas as seis variáveis (incluindo ΔEMBI+ com *prior* heterogêneo), $\sigma^* = 0{,}01$ para os cinco regressores regulares e $\sigma = 0{,}1$ para o EMBI+, via estimador MAP, foi avaliado no conjunto de teste. As métricas obtidas foram MAE = 0,010147, RMSE = 0,014877 e R^2 = 0,2436.

A Figura 6 apresenta a previsão pontual sobreposta aos retornos observados. O estimador MAP não produz intervalos de credibilidade sobre as previsões, apenas previsão pontual. A variante MCMC do BSTS forneceria esses intervalos, mas foi descartada por instabilidade neste conjunto de dados (experimento B4). A previsão acompanha a tendência geral dos retornos, mas atenua as oscilações de alta frequência, comportamento esperado em modelos estruturais bayesianos com encolhimento agressivo.

Diferentemente dos modelos OLS e GAM, o BSTS permite decompor a previsão em

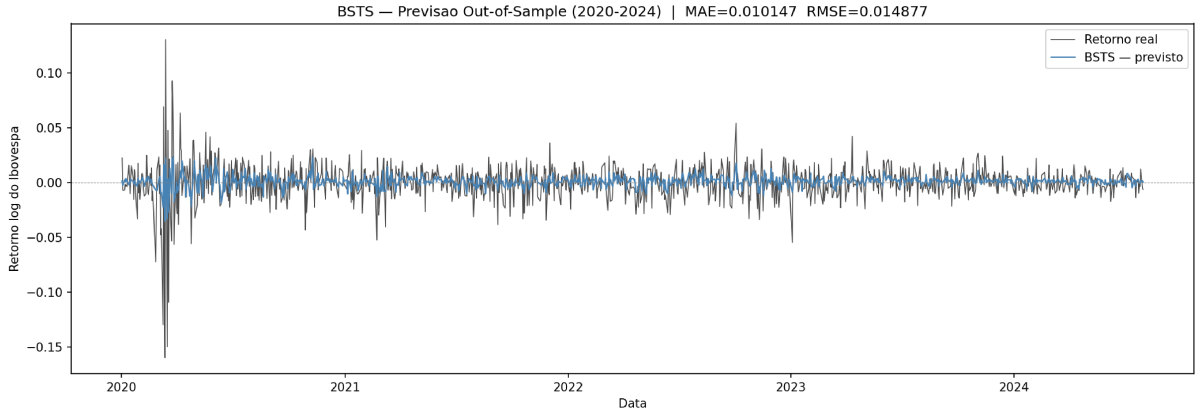


Figura 6 – Previsão pontual BSTS *out-of-sample* (2020–2024) com estimador MAP (Fonte: Autor)

seus componentes estruturais. A Figura 7 ilustra essa decomposição em três blocos: (i) tendência, que captura a direção de longo prazo e absorve mudanças graduais de regime; (ii) sazonalidade semanal, modelada com período de cinco pregões; e (iii) componente de regressão, que reflete o efeito conjunto das variáveis macroeconômicas selecionadas.

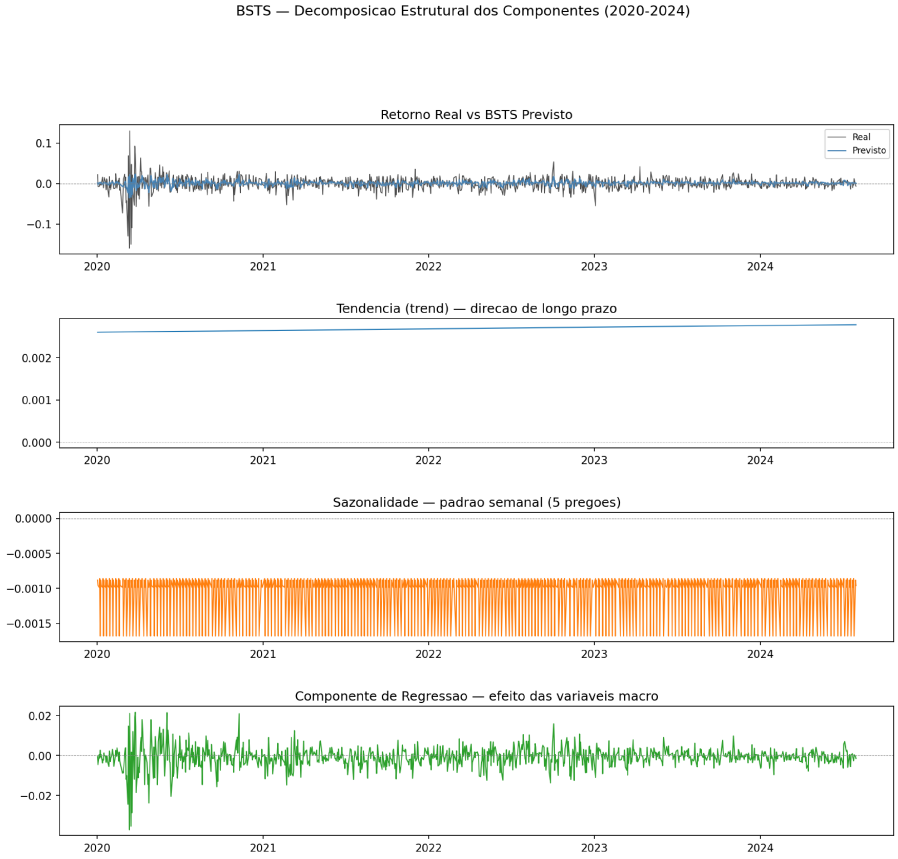


Figura 7 – Decomposição estrutural BSTS: tendência, sazonalidade e regressão sobre o período de teste (Fonte: Autor)

A análise da decomposição revela que a sazonalidade contribui de forma marginal e es-

tável, com amplitude reduzida ao longo do período de teste, indicando que o efeito de calendário semanal é pequeno mas presente. A tendência apresenta variação suave e absorve o pano de fundo do período, marcado pelo choque inicial da pandemia em 2020, pela recuperação e pelo ciclo de aperto monetário entre 2021 e 2023, e pela estabilização em 2024. Já o componente de regressão concentra a maior parte da variabilidade explicada, refletindo a resposta dos retornos às oscilações diárias do câmbio, da Selic e demais variáveis macroeconômicas selecionadas.

7.3.4 Discussão Comparativa: GAM e BSTS

Em desempenho preditivo, o GAM superou o BSTS em todas as métricas: o R^2 *out-of-sample* do GAM (0,3045) é 25% superior ao do BSTS (0,2436), e o MAE é 1,5% menor. A diferença reduziu-se em relação às versões anteriores dos modelos, em grande medida pela reincorporação do EMBI+ no BSTS com *prior* heterogêneo (B7). Há, no entanto, aspectos em que o BSTS oferece valor que nenhum dos demais modelos entrega.

O primeiro aspecto é a inferência bayesiana nativa. Na etapa de seleção de variáveis, as distribuições posteriores dos coeficientes, obtidas por MCMC com 2000 amostras, constituíram o critério de inclusão, substituindo testes de significância clássicos por probabilidades posteriores. Cabe distinguir, contudo, dois planos em que esse rigor probabilístico se manifesta de forma diferenciada. Na fase de treino, o MCMC com 2000 amostras entregou distribuições posteriores completas, permitindo auditar a incerteza sobre cada coeficiente e cada peso de inclusão de variável; esse é o plano em que o rigor bayesiano é pleno. No plano preditivo, a variante MCMC do BSTS produziria, adicionalmente, intervalos de credibilidade dinâmicos sobre as previsões *out-of-sample*, estendendo esse rigor também ao horizonte de teste; porém, como documentado na Seção 5.7, a estimação por MCMC gerou instabilidade numérica no período fora da amostra, levando à adoção do estimador MAP como decisão de engenharia para garantir a convergência das previsões. O resultado é que o modelo, neste trabalho, fornece apenas previsão pontual no conjunto de teste, o que constitui uma limitação declarada: o rigor probabilístico pleno que caracteriza o BSTS no treino não se estende integralmente ao período de avaliação preditiva. Modelos como GAM e OLS não incorporam incerteza paramétrica de forma probabilística nativa, nem permitem quantificar a dispersão da posteriori dos coeficientes.

O segundo aspecto é a decomposição estrutural, que separa explicitamente o que é tendência, sazonalidade e resposta a covariáveis. Essa separação é interpretativamente valiosa porque permite identificar, por exemplo, se uma queda observada nos retornos é atribuível a mudança de regime de longo prazo ou a um choque pontual nas variáveis macro. O GAM, mesmo com PDPs informativos, não oferece essa decomposição temporal explícita.

O terceiro aspecto é a seleção de variáveis no BSTS, que opera sobre um critério probabilístico nativo (posteriori dos coeficientes), enquanto no GAM ela depende de comparações *out-of-sample* de MAE. Ambos os critérios são válidos, mas a versão bayesiana é mais coerente com o arcabouço de inferência adotado e dispensa a definição de um conjunto de teste para essa

etapa.

GAM e BSTS são, portanto, complementares mais do que substitutos. O GAM é superior em previsão pontual e na visualização de não linearidades, enquanto o BSTS adiciona estrutura temporal explícita, decomposição em componentes e inferência bayesiana sobre os coeficientes. Essa complementaridade reforça o argumento, central neste trabalho, de que a escolha do modelo deve ser orientada não apenas pela métrica preditiva, mas também pela natureza da pergunta e pela robustez interpretativa exigida pelo problema.

7.4 Resultados do Modelo Causal Forest

Esta seção apresenta os resultados do modelo Causal Forest estimado sobre a estrutura causal descrita na Seção 5.8: retorno logarítmico do Ibovespa como desfecho, choque cambial binário (limiar $p75 = 0{,}0229$, calculado no treino) como tratamento e oito covariáveis (cinco macroeconômicas domésticas e três variáveis de risco global: VIX, S&P 500 e petróleo Brent) como modificadores de efeito. Diferentemente dos modelos anteriores, cujo objetivo primário é a predição pontual, o Causal Forest busca estimar o efeito causal condicional $\tau(x) = \mathbb{E}[Y(1) - Y(0) \mid X = x]$ (cf. Equação 4.2), admitindo que esse efeito pode variar de acordo com o contexto macroeconômico de cada observação.

7.4.1 Efeito Causal Médio e Distribuição do CATE

A estimação do ATE (Average Treatment Effect) no conjunto de teste (2020–2024) resultou em ATE $= +0{,}000075$, com intervalo de confiança de 95% $= [-0{,}00301;\ +0{,}00316]$. O zero está contido no intervalo, de modo que o efeito causal *médio* de um dia de choque cambial sobre o retorno do Ibovespa não é estatisticamente distinto de zero. Esse resultado, longe de ser vacuoso, é a primeira evidência de que o impacto do câmbio sobre o mercado acionário é heterogêneo e condicionado tanto pelo contexto macroeconômico vigente quanto pela heterogeneidade setorial estrutural da economia brasileira: o efeito médio nulo emerge da soma de efeitos positivos e negativos de magnitudes similares, não de ausência de influência. Empresas exportadoras de commodities — como siderúrgicas, petroquímicas e mineradoras — tendem a se beneficiar de depreciações cambiais, já que suas receitas são dolarizadas; empresas importadoras ou com dívidas denominadas em moeda estrangeira são prejudicadas pelo mesmo choque. O Ibovespa, por reunir em um único índice empresas com essas exposições estruturalmente opostas, produz naturalmente esse cancelamento agregado — o peso relativo de cada grupo no índice, mediado pelo contexto de risco soberano do momento, determina qual força prevalece.

A Figura 8 apresenta a distribuição do CATE estimado no período de teste. As estimativas pontuais variam de $-0{,}003965$ a $+0{,}004649$, com mediana de $-0{,}000005$ e desvio padrão de 0,001553. Aproximadamente 50,1% dos dias de teste apresentam efeito estimado negativo,

distribuição quase simétrica ao redor de zero que é coerente com o ATE não distinto de zero e com a ausência de predominância de um sinal sobre o outro no período 2020–2024.

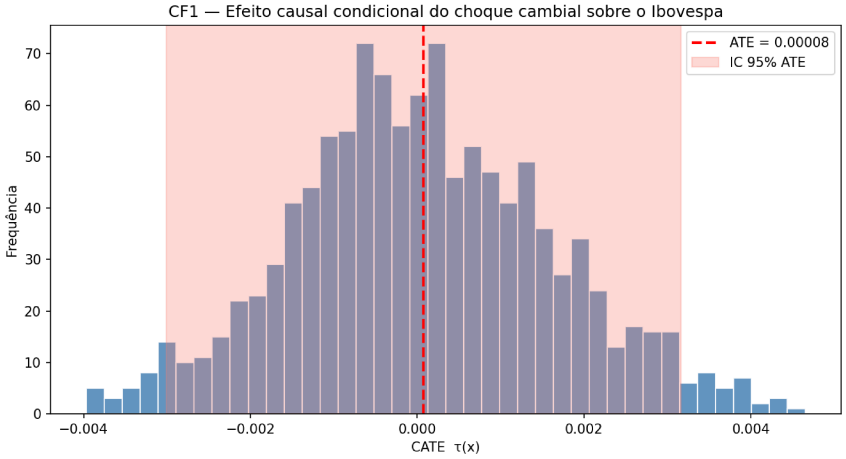


Figura 8 – Distribuição do CATE estimado pelo Causal Forest no conjunto de teste (2020–2024). A linha vertical indica o ATE $= +0{,}000075$, cujo intervalo de confiança de 95% cruza zero. A dispersão de $\tau(x)$ ao redor do ATE nulo evidencia a heterogeneidade do efeito causal condicional (Fonte: Autor)

Cabe registrar um aspecto metodológico relevante sobre o período de teste: a prevalência de dias de choque cambial (T = 1) foi de 25,0% no treino (2001–2019) e de 55,9% no conjunto de teste (2020–2024). Essa assimetria não é um artefato do desenho, mas reflete a maior volatilidade cambial do período posterior, associada à pandemia de COVID-19 e ao ciclo de aperto monetário que elevou a Selic a 13,75% ao ano. Ela se conecta diretamente ao achado central desta seção: num ambiente em que choques cambiais são mais frequentes, o efeito causal médio tende a refletir uma mistura de contextos mais diversificada, tornando a heterogeneidade do CATE ainda mais relevante como instrumento analítico.

7.4.2 Calibração do CATE pelo Best Linear Predictor

Para avaliar se a heterogeneidade estimada pelo forest é estatisticamente real ou apenas ruído de estimação, foi aplicado o Best Linear Predictor (BLP) de Chernozhukov et al. (2018b). Nesse procedimento, o CATE observado é regredido sobre o CATE estimado pelo modelo, e o coeficiente angular β_1 testa a hipótese nula de ausência de heterogeneidade ($H_0 : \beta_1 = 0$). Os modelos de nuisance do BLP ($\hat{m}$ e $\hat{e}$) foram ajustados por cross-fitting temporal de cinco folds dentro do conjunto de teste, dado que o regime cambial e de juros do período 2020–2024 difere substancialmente do treino.

Os resultados foram $\beta_1 = 51{,}70$, IC 95% $= [29{,}51;\ 73{,}89]$, com $p < 0{,}001$, rejeitando H_0. A calibração pelo Best Linear Predictor de Chernozhukov et al. (2018b) rejeita $H_0 : \beta_1 = 0$ ao nível de 1%, confirmando que o forest captura heterogeneidade estatisticamente significativa do efeito condicional e não apenas ruído. O valor absoluto de $\beta_1 \gg 1$ é um artefato do encolhimento (*shrinkage*) inerente à estimação honesta das folhas: o `CausalForestDML` encolhe

$\hat{\tau}(x)$ em direção a zero para garantir a consistência dos intervalos de confiança do CATE, de modo que as estimativas pontuais são sistematicamente subestimadas em escala; o BLP recupera a escala correta ao regredir o CATE observado sobre o estimado, e o slope $\gg 1$ indica que a ordenação da heterogeneidade foi capturada corretamente, ainda que sua magnitude absoluta esteja comprimida. A interpretação relevante para este trabalho foca na significância estatística como evidência de heterogeneidade real.

7.4.3 Heterogeneidade por Grupo: GATES

Para descrever a estrutura da heterogeneidade de forma interpretável, foram calculados os GATES (Group Average Treatment Effects) por decil do CATE estimado $\hat{\tau}(x)$. Cada decil agrupa aproximadamente 112 observações do conjunto de teste; o efeito médio dentro de cada grupo e seu intervalo de confiança de 95% são apresentados na Figura 9.

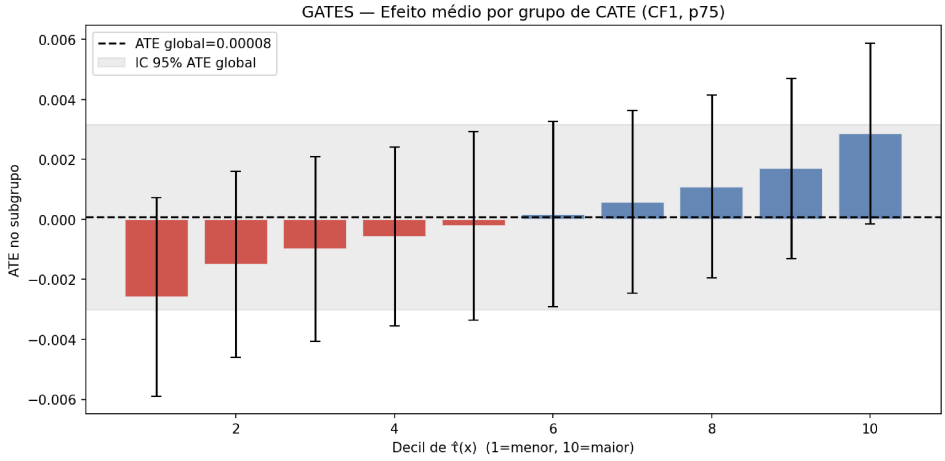


Figura 9 – GATES por decil do CATE estimado: efeito médio de tratamento em cada grupo, com intervalos de confiança de 95%. Os GATES exibem monotonicidade estritamente crescente, de $-0{,}002581$ (decil 1) a $+0{,}002867$ (decil 10). Nenhum decil individualmente apresenta IC inteiramente fora de zero, resultado consistente com o tamanho amostral do período de teste; a heterogeneidade é detectável globalmente pelo BLP ($\beta_1 = 51{,}70$, $p < 0{,}001$) (Fonte: Autor)

Os GATES exibem monotonicidade estritamente crescente ao longo dos decis, de $-0{,}002581$ (decil 1) a $+0{,}002867$ (decil 10), com amplitude total de aproximadamente 0,005, valor próximo a três vezes o desvio padrão do CATE (0,0016). Nenhum decil individualmente apresenta intervalo de confiança inteiramente fora de zero, resultado coerente com o tamanho amostral do período de teste e com a expansão do vetor de covariáveis para oito variáveis, que redistribui a variância do CATE entre um espaço mais amplo. A heterogeneidade é, contudo, detectável globalmente pelo BLP ($\beta_1 = 51{,}70$, $p < 0{,}001$): a ausência de significância individual por decil não indica ausência de heterogeneidade real, mas reflete que a amplitude do efeito condicional é moderada e que a ordenação monotônica é capturada corretamente pelo forest. O resultado é coerente com o ATE nulo: a soma de efeitos de sinais opostos produz uma mé-

dia não distinguível de zero, enquanto a estrutura de heterogeneidade entre grupos permanece identificada.

7.4.4 Covariáveis que Modulam o Efeito: Importância e PDPs

A importância das covariáveis na determinação da heterogeneidade de $\tau(x)$ foi calculada pelo critério nativo do `CausalForestDML`, que mede a contribuição de cada variável à variação do efeito condicional entre as partições do forest. Com o vetor expandido para oito covariáveis, o ΔEMBI+ (`embi_brasil_diff`) continua sendo a variável dominante, respondendo por 32,6% da heterogeneidade do CATE, mas sua participação caiu substancialmente em relação à configuração anterior com apenas variáveis domésticas (onde respondia por 72,9%), porque agora a variância antes atribuída ao risco-país se distribui entre os canais interno e global. O PIB (`br_pib_ret_log`) dobrou sua contribuição relativa, de 10,9% para 20,1%, emergindo como o segundo canal mais relevante quando o contexto internacional é explicitamente controlado pelo modelo. O IPCA (`br_ipca`) manteve participação similar, com 19,0%. As três variáveis globais incorporadas somam 28,4% da heterogeneidade: o retorno do petróleo Brent responde por 10,1%, o S&P 500 por 9,3% e o VIX por 9,0%. Esse resultado confirma empiricamente a hipótese motivadora da expansão: choques cambiais no Brasil têm componente de aversão ao risco global relevante, e o modelo passa a discernir se a heterogeneidade do efeito causal decorre de vulnerabilidades macroeconômicas internas ou de movimentos generalizados de fuga de capital global. A Selic (`br_selic_diff`) e as expectativas de inflação (`ipca_expectativa_diff`) mantiveram importância nula, resultado coerente com a hipótese de eficiência semi-forte — o mercado antecipa decisões de política monetária, de modo que o canal de juros não produz heterogeneidade adicional no efeito causal condicional.

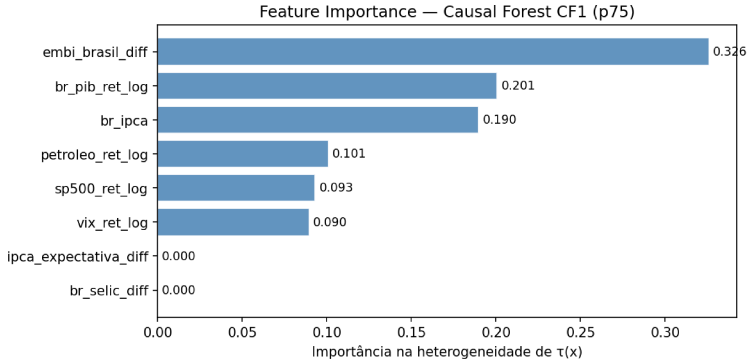


Figura 10 – Importância das covariáveis na heterogeneidade do CATE, calculada pelo critério nativo do `CausalForestDML`. Com oito covariáveis, o ΔEMBI+ (risco-país) responde por 32,6% da variação do efeito condicional, seguido do PIB (20,1%), IPCA (19,0%) e das três variáveis globais somadas (28,4%: petróleo 10,1%, S&P 9,3%, VIX 9,0%) (Fonte: Autor)

A interpretação econômica articula duas dimensões complementares. Do ponto de vista macroeconômico, quando o prêmio de risco soberano está elevado, choques cambiais tendem

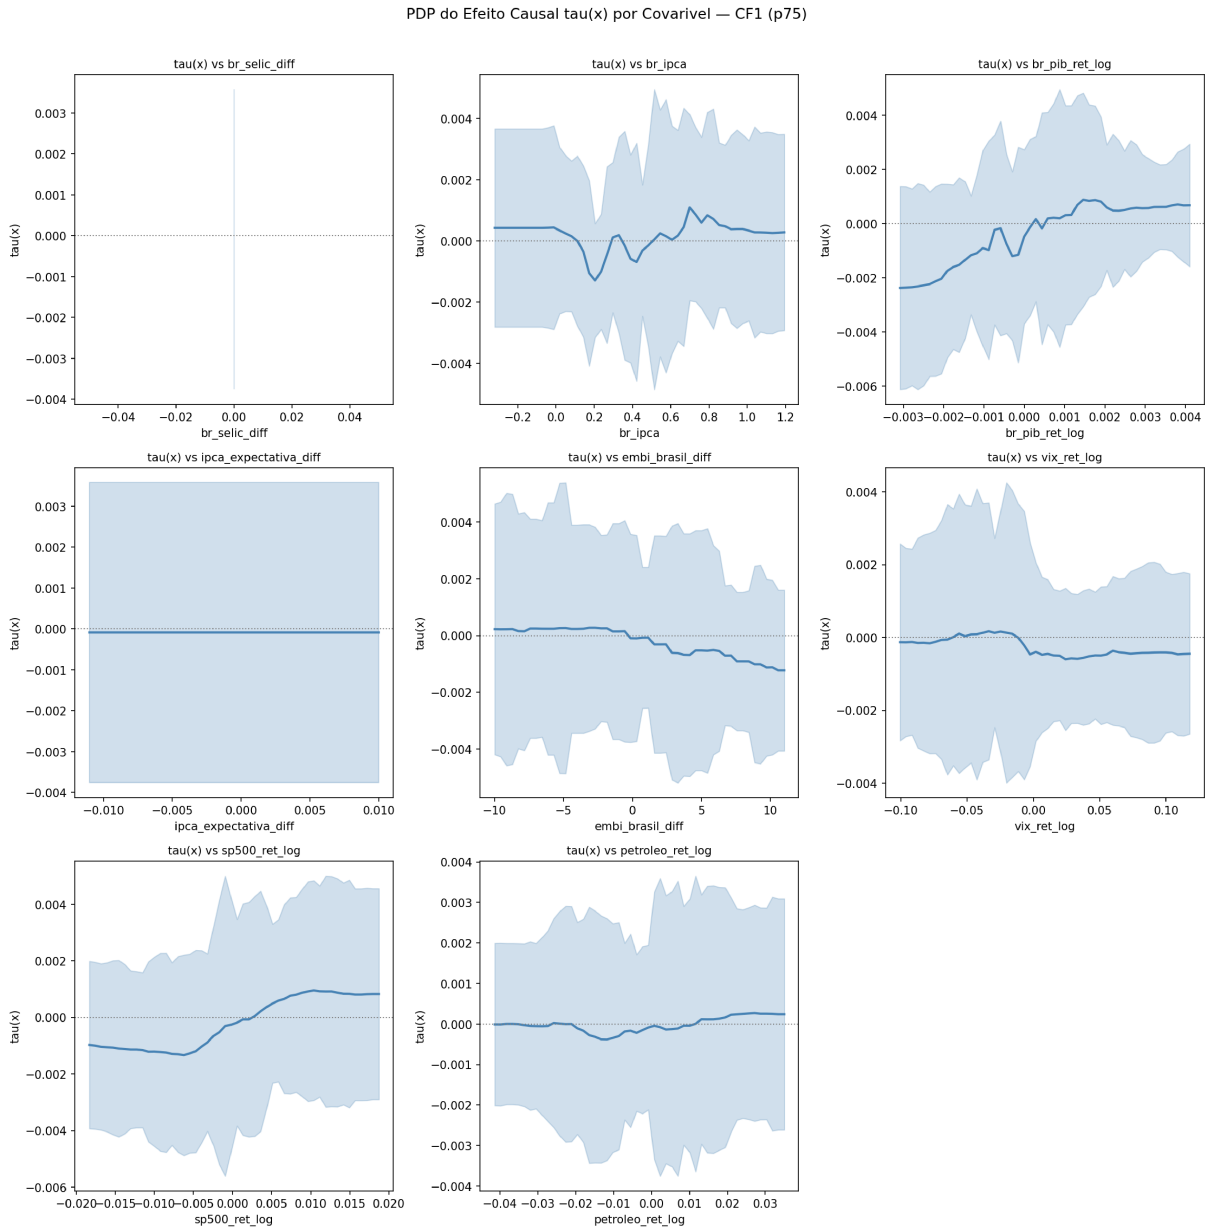


Figura 11 – PDPs do CATE estimado em função de cada covariável: efeito marginal da variável sobre a heterogeneidade do efeito causal do choque cambial. A curva do ΔEMBI+ exibe relação negativa, com o efeito do choque tornando-se mais negativo à medida que o risco soberano aumenta (Fonte: Autor)

a amplificar saídas de capital e aversão a risco, produzindo efeitos mais negativos sobre o Ibovespa; em contextos de risco-país baixo, o mesmo choque pode ser assimilado com menor impacto sobre os ativos domésticos, ou até associado a ajustes de fluxos comerciais com efeito positivo no curtíssimo prazo. Do ponto de vista setorial, o EMBI+ atua como modulador que determina qual força prevalece em cada episódio: em momentos de risco soberano elevado, a fuga de capitais penaliza desproporcionalmente as empresas com maior exposição ao câmbio passivo (importadoras e endividadas em moeda estrangeira), enquanto em ambientes de risco contido as exportadoras de commodities tendem a capturar parte do efeito positivo da depreciação — padrão coerente com a estrutura do Ibovespa, que combina esses dois perfis de empresas.

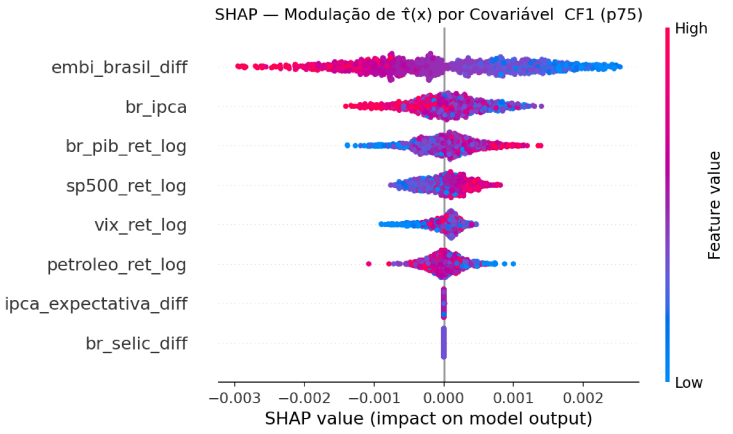


Figura 12 – Valores SHAP para o CATE estimado (LUNDBERG; ALLEN; LEE, 2017): cada ponto representa uma observação do conjunto de teste, e a posição horizontal indica a contribuição da covariável para o afastamento de $\hat{\tau}(x)$ em relação ao ATE. O ΔEMBI+ domina, com valores SHAP elevados em dias de alto risco-país associados a efeitos causais mais negativos (Fonte: Autor)

O IPCA e o PIB contribuem com cerca de 39% da heterogeneidade (com destaque para o PIB, cujo peso relativo dobrou quando o contexto global passou a ser explicitamente controlado), indicando que o contexto inflacionário e de atividade econômica também modula a reação do mercado acionário a variações cambiais de maneira que modelos lineares não conseguem capturar de forma condicional. As variáveis globais, por sua vez, acrescentam uma dimensão estrutural: o preço do petróleo Brent, o desempenho do S&P 500 e a volatilidade implícita do mercado americano (VIX) atuam conjuntamente como sinalizadores do apetite global por risco, determinando se um choque cambial doméstico será amplificado ou amortecido pelo contexto internacional vigente.

7.4.5 Robustez da Escolha do Limiar

A robustez da definição de choque cambial foi avaliada comparando três limiares alternativos. A Tabela 9 apresenta os resultados para cada configuração.

Limiar	Threshold	Prev. treino	Prev. teste	R^2_teste	MAE	RMSE	ATE (IC 95%)
$p70$	0,0197	30,0%	60,5%	0,4001	0,009707	0,013248	$+0{,}000$ ($[-0{,}0026;\ +0{,}0034]$)
$p75$	**0,0229**	**25,0%**	**55,9%**	**0,4028**	**0,009663**	**0,013219**	$+0{,}000$ ($[-0{,}0030;\ +0{,}0032]$)
$p80$	0,0270	20,0%	50,2%	0,3826	0,009653	0,013441	$-0{,}000$ ($[-0{,}0040;\ +0{,}0038]$)

Tabela 9 – Comparativo de desempenho entre os três limiares de choque cambial ($p70$, $p75$, $p80$). Em todos os casos, o ATE não é estatisticamente distinto de zero e a heterogeneidade permanece detectável. O limiar $p75$ (negrito) foi adotado como configuração principal por combinar o melhor R^2 preditivo com a justificativa convencional na literatura de volatilidade cambial.

Em todos os três limiares, o ATE permanece não distinto de zero, com todos os intervalos de confiança cruzando zero. A conclusão qualitativa central — efeito médio nulo, heterogeneidade real e modulada predominantemente pelo risco soberano — é portanto robusta à

escolha do corte, variando apenas em intensidade. O limiar $p75$ combina o melhor desempenho preditivo com a referência convencional e foi mantido como configuração principal.

7.4.6 Reconstrução Preditiva e Posicionamento Comparativo

Embora o objetivo primário do Causal Forest seja causal, é possível reconstruir uma previsão preditiva pela fórmula $\hat{Y} = \hat{m}_0(X) + \hat{\tau}(X) \cdot T$, onde $\hat{m}_0(X)$ é estimado apenas sobre os dias de controle ($T = 0$) do conjunto de treino. Essa reconstrução permite comparar o modelo com os demais em termos preditivos, com a ressalva de que não constitui o critério de estimação adotado e de que a comparação não é simétrica, já que o Causal Forest dispõe de três covariáveis globais ausentes dos demais modelos e incorpora o tratamento observado na reconstrução.

No conjunto de teste (2020–2024), a reconstrução com oito covariáveis produziu MAE = 0,009663, RMSE = 0,013219 e R^2 = 0,4028. Em relação à configuração anterior com cinco covariáveis domésticas (MAE = 0,010509, RMSE = 0,014990, R^2 = 0,2321), o ganho foi de 17,1 pontos percentuais em R^2, com reduções de 8,0% no MAE e 11,8% no RMSE. O modelo supera o GAM em R^2_teste (0,4028 contra 0,3045), embora o GAM mantenha os melhores valores absolutos de MAE e RMSE, resultado coerente com o fato de o tuning do Causal Forest ter minimizado R-loss causal, não R^2 preditivo, e a estimação honesta das folhas introduzir encolhimento intencional que reduz a variância das estimativas ao custo de algum viés. O valor do método está na dimensão causal (na identificação de quem é afetado, de quanto e por qual canal macroeconômico), e a expansão para variáveis globais demonstrou que a inclusão do contexto internacional era, de fato, a informação omitida de maior impacto na reconstrução preditiva.

7.5 Síntese Comparativa dos Modelos

A Tabela 10 consolida o desempenho de todos os modelos estimados ao longo do trabalho, lado a lado: à esquerda, as métricas *in-sample* da linha de base (sobre o conjunto completo dos dados) e, à direita, as métricas *out-of-sample* obtidas no conjunto de teste (jan/2020–jul/2024).

O achado mais significativo desta síntese transcende qualquer métrica individual: três métodos matematicamente distintos — o GAM (modelo aditivo não linear), o BSTS (estrutural bayesiano) e o Causal Forest (inferência causal heterogênea) — chegaram, de forma independente entre si, à mesma conclusão sobre o determinante dominante do retorno do Ibovespa. Nos PDPs do GAM, o ΔEMBI+ emergiu como a variável com maior ganho não linear, exibindo assimetria e saturação em choques extremos que o OLS não conseguia capturar. No BSTS, o encolhimento uniforme suprimiu inicialmente o EMBI+ na parametrização padrão, e somente a ampliação deliberada do *prior* — motivada pela evidência cruzada do GAM — permitiu que

Modelo	R²_base	MAE_base	R²_teste	MAE_teste	RMSE_teste
ARIMA(4, 0, 3)	—	0,012225	—	—	—
OLS / MQO	0,2086	0,011093	0,2339	0,010351	0,014971
GAM (final)	0,2946	0,010758	0,3045	**0,009997**	**0,014265**
BSTS (final)	—	—	0,2436	0,010147	0,014877
Causal Forest	—	—	**0,4028**	0,009663	0,013219

Tabela 10 – Comparativo completo de métricas: linha de base *in-sample* (conjunto completo) e avaliação *out-of-sample* (teste: jan/2020–jul/2024). O melhor desempenho preditivo fora da amostra está destacado em negrito. As métricas do Causal Forest referem-se à reconstrução $\hat{Y} = \hat{m}_0(X) + \hat{\tau}(X) \cdot T$, cujo objetivo primário é causal, não preditivo.

seu efeito se manifestasse, com ganho de 10 pontos percentuais em R²_teste. No Causal Forest, o ΔEMBI+ respondeu por 32,6% da variação do efeito causal condicional, emergindo como o principal modulador da heterogeneidade do CATE. Essa triangulação metodológica, obtida sem coordenação entre os modelos e por arcabouços com fundamentos matemáticos inteiramente diferentes, confere ao resultado uma robustez interpretativa que nenhum método isolado poderia oferecer.

Além desse achado central, outras leituras complementam a síntese. O Causal Forest, com a expansão do vetor de covariáveis para oito variáveis, alcançou R²_teste de 0,4028, o maior entre todos os modelos, mas esse valor deve ser lido como métrica secundária e não diretamente comparável: o modelo dispõe de três covariáveis globais ausentes dos demais e utiliza o tratamento observado na reconstrução preditiva, tendo sido otimizado por critério causal, não preditivo; o GAM mantém os melhores resultados em MAE (0,009997) e RMSE (0,014265). O OLS apresentou R²_teste (0,2339) superior ao R²_base (0,2086), sugerindo que as relações lineares entre câmbio, risco-país e retornos do Ibovespa se intensificaram no período pós-2020, marcado pela pandemia de COVID-19 e pelo ciclo de aperto monetário. O BSTS, com R²_teste de 0,2436, agrega elementos que os modelos pontuais não oferecem: decomposição estrutural da série e seleção probabilística de variáveis por distribuições posteriores. Por fim, o ATE nulo do Causal Forest ($+0{,}000075$, IC 95% cruzando zero) confirma que o efeito do câmbio sobre o Ibovespa é heterogêneo e regime-dependente, com efeitos de sinais opostos que se cancelam na média — resultado que não contradiz, mas complementa, os efeitos médios estimados pelos demais modelos.

Essa leitura comparativa precisa ser complementada por um reconhecimento estrutural sobre a natureza do período de teste. Os anos de 2020–2024 contêm eventos com poucos análogos no histórico de treino, como a pandemia de COVID-19, o ciclo de elevação da Selic de 2,00% para 13,75% ao ano e a recomposição cambial subsequente, o que torna a leitura das métricas *out-of-sample* indissociável da hipótese de mudança de regime econômico. A Crítica de Lucas (LUCAS, 1976) sustenta, em sua formulação clássica, que parâmetros estimados a partir de séries históricas podem perder estabilidade quando o regime de política se desloca; evidências empíricas em economias desenvolvidas confirmam que tal instabilidade é

particularmente visível em transições de regime (LUBIK; SURICO, 2010) e que algoritmos de aprendizado de máquina, embora aproximem expectativas racionais sob choques moderados, encontram dificuldade adicional diante de mudanças paradigmáticas (CASTELNUOVO; GALIMBERTI; SUARDI, 2022). Esse enquadramento sugere que a queda do R^2 do treino para o teste não deve ser atribuída exclusivamente a sobreajuste, mas também, em parte, à hipótese de que as relações capturadas durante 2001–2019 são, em alguma medida, específicas ao regime econômico vigente naquele período. A interpretabilidade estrutural dos modelos, expressa nas não linearidades do GAM, na decomposição do BSTS e na heterogeneidade condicional do Causal Forest, preserva sua validade descritiva sobre o regime histórico de treinamento, ainda que a generalização para regimes futuros distintos exija cautela adicional. Cabe distinguir, por fim, dois níveis de interpretabilidade oferecidos pelo conjunto de modelos: o GAM e o BSTS produzem interpretabilidade global, descrevendo a forma das relações e a estrutura temporal sobre todo o conjunto de dados, ao passo que o Causal Forest oferece interpretabilidade local, estimando o efeito condicional do tratamento observação a observação. A estrutura interna de florestas é, em si, opaca, mas o objeto de interesse não é essa estrutura e sim a saída local (o CATE), que permanece interpretável, assintoticamente consistente e dotada de intervalos de confiança válidos sob a estimação honesta.

8 Conclusão

Este trabalho demonstrou que modelos explicativos com IA interpretável constituem uma abordagem viável, complementar e teoricamente coerente para a análise de mercados financeiros em economias emergentes. A linha de base ARIMA e MQO, estimada sobre retornos diários do Ibovespa entre 2001 e 2019, estabeleceu os primeiros parâmetros de referência: o ARIMA, por ser univariado, projeta a série apenas a partir de sua própria dinâmica, sem incorporar variáveis explicativas externas; o MQO, embora tenha identificado relações estatisticamente significativas como os efeitos negativos do câmbio e do risco-país, apresentou baixa capacidade preditiva ($R^2 = 0{,}209$) e falhas nos pressupostos de homocedasticidade e normalidade dos resíduos, além de ser estruturalmente incapaz de capturar não linearidades complexas e mudanças de regime ao longo do tempo. Essas limitações motivaram a aplicação dos modelos de IA interpretável que compõem o núcleo analítico deste trabalho.

Cada modelo contribuiu com uma perspectiva distinta sobre a dinâmica dos retornos do Ibovespa. O GAM capturou as não linearidades e assimetrias nas relações entre variáveis macroeconômicas e retornos, revelando que o risco-país exibe saturação em choques extremos e que o câmbio opera de forma assimétrica em grandes desvalorizações. O BSTS decompôs a série em componentes estruturais e ofereceu inferência probabilística sobre os coeficientes, separando tendência, sazonalidade e efeitos de regressão de forma auditável. O Causal Forest revelou a heterogeneidade do efeito causal do câmbio, condicionada pelo nível de risco soberano e pelo contexto de risco global, com heterogeneidade estatisticamente real confirmada pelo Best Linear Predictor.

A convergência dos três modelos em torno do papel central do ΔEMBI+ como principal canal de transmissão macroeconômica é o resultado mais robusto do trabalho. Que três arcabouços com fundamentos matemáticos inteiramente diferentes — funções suaves aditivas, decomposição estrutural bayesiana e florestas causais — apontem independentemente para o mesmo determinante dominante é evidência de que o resultado reflete uma estrutura econômica real, não um artefato de modelagem. A interpretabilidade, nesse contexto, não é apenas um requisito regulatório: é o instrumento que torna possível essa leitura integrada e cruzada dos resultados.

A aplicação do modelo GAM confirmou empiricamente a capacidade de modelos aditivos de capturar relações não lineares que os modelos tradicionais não detectam. Com R^2 de 0,3045 no conjunto de teste (2020–2024) e MAE de 0,009997, o GAM apresentou ganho explicativo em relação ao MQO ($R^2 = 0{,}2086$ *in-sample*) e boa capacidade de generalização para um período estruturalmente distinto. O processo de otimização utilizou um *holdout* interno (2018–2019) para selecionar $n^* = 10$ splines e avaliar a forma funcional por variável, evitando a

contaminação do critério de seleção pelo conjunto de teste. Dois ajustes adicionais foram aceitos: a transformação do IPCA para primeiras diferenças, corrigindo inconsistência estocástica no vetor de preditores, e a inclusão do retorno do Ibovespa defasado em um pregão como *feature* autorregressiva — ganho marginal e parcial em relação ao R^2 total do modelo. A análise dos PDPs revelou que o risco-país é o canal com maior ganho não linear, exibindo assimetria e saturação em choques extremos, e que câmbio e risco-país juntos respondem pelos efeitos de transmissão macroeconômica mais robustos. A proximidade do R^2 entre treino (0,2946) e teste reforça a ausência de sobreajuste e a validade do modelo como instrumento explicativo para além do período de estimação.

A estimação do modelo BSTS adicionou uma perspectiva dinâmica e probabilística à análise. Com R^2_teste = 0,2436 e MAE = 0,010147, alcançados após a reincorporação do ΔEMBI+ com *prior* heterogêneo, o BSTS contribuiu com elementos que nenhum dos demais modelos oferece: a decomposição estrutural da série em tendência, sazonalidade e regressão; a seleção de variáveis baseada em probabilidades posteriores obtidas por MCMC, em vez de testes de significância clássicos; e a regularização bayesiana explícita via `sigma_prior`. A busca em grade identificou $\sigma^* = 0{,}01$ como encolhimento ótimo, valor mais restritivo do que a grade original capturava, indicando que retornos diários exigem regularização muito forte para evitar absorção de ruído. A reincorporação do EMBI+ com prior dez vezes mais amplo mostrou que sua supressão na parametrização uniforme era artefato da competição com o componente de tendência e da correlação parcial com o câmbio, não ausência de efeito real. GAM e BSTS cobrem, assim, dimensões complementares do problema: o primeiro caracteriza a forma não linear das relações entre covariáveis e retornos; o segundo, a evolução temporal e a incerteza associada à previsão.

A aplicação do Causal Forest concluiu o ciclo de modelos propostos, acrescentando à análise a dimensão causal que os modelos preditivos anteriores não abordam. O efeito causal médio de um dia de choque cambial sobre o retorno do Ibovespa não foi estatisticamente distinto de zero (ATE $= +0{,}000075$, IC 95% cruzando zero), resultado que, interpretado corretamente, não indica ausência de efeito, mas sim a existência de efeitos heterogêneos de sinais opostos que se cancelam na média — reflexo parcial da composição setorialmente heterogênea do Ibovespa, que combina exportadoras de commodities beneficiadas pela depreciação cambial e empresas importadoras ou endividadas em moeda estrangeira prejudicadas pelo mesmo choque. A calibração pelo Best Linear Predictor de Chernozhukov et al. (2018b) confirmou a significância estatística dessa heterogeneidade ($\beta_1 = 51{,}70$, $p < 0{,}001$), e a análise de GATES revelou padrão monotônico crescente com amplitude total de aproximadamente 0,005 entre os grupos de menor e maior efeito condicional — nenhum decil individualmente apresenta IC fora de zero, mas a heterogeneidade global é estatisticamente real.

O risco-país (ΔEMBI+) emergiu como o principal modulador do efeito causal, respondendo por 32,6% da variação do CATE, seguido do PIB (20,1%), IPCA (19,0%) e das variáveis

globais somadas (28,4%), o que reforça a tese central de que a relação entre câmbio e mercado acionário no Brasil não é uniforme, mas condicionada pelo ambiente de risco soberano e pelo contexto internacional. Esse resultado é coerente com a evidência do GAM de que o EMBI+ é a variável com maior ganho não linear, e com o achado do BSTS de que o encolhimento uniforme dos coeficientes suprime o efeito do EMBI+ — os três modelos convergem para uma descrição consistente do papel central do risco soberano na transmissão macroeconômica sobre o Ibovespa. As hipóteses de identificação causal do Causal Forest — ignorabilidade, suporte comum e as duas dimensões da SUTVA — são discutidas em detalhe na Seção 5.8.1; a premissa de ignorabilidade, em particular, permanece como hipótese não testável dado o conjunto de covariáveis observadas disponível. A reconstrução preditiva ($R^2 = 0{,}4028$, MAE = 0,009663) supera o GAM em R^2 e confirma que a inclusão do contexto de risco global era a variável omitida de maior impacto, resultado esperado dado que o tuning foi orientado por critério causal, não preditivo.

A interpretação dos resultados deve, contudo, observar limitações de duas ordens. Do lado dos dados e do domínio, a Crítica de Lucas (LUCAS, 1976) é o enquadramento fundamental: por se basearem em padrões estatísticos extraídos de séries históricas, o GAM e o BSTS herdam o problema de que suas estimativas refletem as regras de decisão dos agentes econômicos sob o regime de política vigente no período de estimação, de modo que a leitura dos modelos como instrumentos explicativos preserva sua validade para o regime histórico que produziu os parâmetros, mas demanda cautela quando se considera sua aplicação a períodos atravessados por mudanças sistemáticas de política monetária, fiscal ou cambial — precisamente o tipo de cenário ao qual o conjunto de teste 2020–2024 esteve exposto. A imputação do preço do petróleo como zero nos pregões anteriores a julho de 2007, decisão documentada na Seção 5.8, integra também essa categoria: a ausência da série histórica do contrato BZ=F cria retornos nulos sistemáticos por quase seis anos da janela de treino, com risco de introduzir um choque deflacionário artificial na covariável — a busca de séries históricas alternativas, como as disponíveis no Ipeadata, representa um passo de baixo custo para trabalhos futuros.

As limitações decorrentes de escolhas de projeto são quatro. A opção pe la janela temporal fixa, embora preserve comparabilidade direta entre modelos, abdica das vantagens potenciais de janelas adaptativas em ambientes com instabilidade estrutural (INOUE; JIN; ROSSI, 2017). A assimetria do espaço de covariáveis, decorrente da inclusão de variáveis globais (VIX, S&P 500 e preço do petróleo) exclusivamente no Causal Forest, produz um espaço heterogêneo na comparação e implica que diferenças de acurácia entre modelos devem ser interpretadas considerando essa assimetria informacional. A adoção do estimador MAP no BSTS implicou a ausência de intervalos de credibilidade dinâmicos nas previsões *out-of-sample*, custo de engenharia para contornar instabilidade numérica identificada na otimização (cf. Seção 5.7), cujo resultado prático é a ausência de quantificação explícita da incerteza preditiva. Por fim, a estrutura interna do Causal Forest, um ensemble de árvores cujos mecanismos individuais não são diretamente legíveis, assemelha-se mecanisticamente aos modelos opacos que o argumento

central deste trabalho critica, sendo sua inclusão justificada pela natureza interpretável das saídas produzidas — o efeito causal heterogêneo $\tau(x)$ é estimado diretamente, sem necessidade de técnicas de explicação *post hoc* — e não pela transparência dos mecanismos internos, distinção que delimita o escopo do argumento de interpretabilidade adotado e deve ser mantida em vista ao avaliar a posição do Causal Forest no espectro dos modelos considerados.

Esses limites, longe de invalidar as conclusões alcançadas, delineiam caminhos naturais de extensão do trabalho. Entre eles, destacam-se a adoção de janelas adaptativas ou *rolling* na avaliação *out-of-sample*, a inclusão de modelos opacos de alta capacidade preditiva — como *gradient boosting* (XGBoost) e redes neurais recorrentes — em papel estritamente comparativo, sem pretensão interpretativa (extensão não realizada por limitação de escopo desta versão), de modo a estabelecer um limite superior de acurácia e evidenciar o custo efetivo de interpretabilidade no contexto estudado, e experimentos de robustez com outros mercados, como setores específicos da bolsa brasileira, *small caps* e índices de economias emergentes comparáveis, que permitiriam avaliar em que medida as conclusões sobre o papel do risco soberano se generalizam além do Ibovespa. Complementarmente, o acompanhamento da regulamentação em curso na Autoridade Nacional de Proteção de Dados, cujos desdobramentos podem reorientar as exigências de explicabilidade aplicáveis a modelos quantitativos de risco no Brasil, constitui uma agenda paralela de relevância prática (Autoridade Nacional de Proteção de Dados (ANPD), 2025).

Referências

ASSOUS, M. Kalecki's 1934 model vs. the is-lm model of hicks (1937) and modigliani (1944)*. *The European Journal of the History of Economic Thought*, Routledge, v. 14, n. 1, p. 97–118, 2007. Disponível em: <https://doi.org/10.1080/09672560601168488>. Citado na página 16.

ATHEY, S.; IMBENS, G. Recursive partitioning for heterogeneous causal effects. *Proceedings of the National Academy of Sciences*, v. 113, n. 27, p. 7353–7360, 2016. Citado na página 28.

ATHEY, S.; IMBENS, G. W. Machine learning methods that economists should know about. *Annual Review of Economics*, v. 11, p. 685–725, 2019. Citado na página 29.

ATHEY, S.; TIBSHIRANI, J.; WAGER, S. Generalized random forests. *The Annals of Statistics*, v. 47, n. 2, p. 1148–1178, 2019. Citado na página 39.

ATHEY, S.; WAGER, S. Estimating treatment effects with causal forests: An application. *Observational Studies*, v. 5, n. 2, p. 37–51, 2019. Citado na página 28.

Autoridade Nacional de Proteção de Dados (ANPD). *Nota Técnica nº 12/2025/CON1/CGN/ANPD: resultados da Tomada de Subsídios sobre tratamento de dados pessoais em sistemas de inteligência artificial e revisão de decisões automatizadas*. 2025. Autoridade Nacional de Proteção de Dados. Disponível em: <https://www.gov.br/anpd-/pt-br/assuntos/noticias/anpd-apresenta-resultados-da-tomada-de-subsidios-sobre-tratamento-automatizado-de-dados-pessoais>. Acesso em: 11.5.2026. Citado 2 vezes nas páginas 13 e 68.

Banco Central do Brasil. *Resolução CMN nº 4.557, de 23 de fevereiro de 2017: Dispõe sobre a estrutura de gerenciamento de riscos e a estrutura de gerenciamento de capital*. 2017. Conselho Monetário Nacional. Disponível em: <https://normativos.bcb.gov.br/Lists-/Normativos/Attachments/50344/Res_4557_v4_L.pdf>. Acesso em: 11.5.2026. Citado 2 vezes nas páginas 13 e 25.

Banco Central do Brasil. *Resolução CMN nº 4.966, de 25 de novembro de 2021: Dispõe sobre os conceitos e o tratamento contábil de instrumentos financeiros, bem como dos ganhos e perdas associados, pelas instituições financeiras*. 2021. Conselho Monetário Nacional. Disponível em: <https://normativos.bcb.gov.br/Lists/Normativos/Attachments-/53464/Res_4966_v1_O.pdf>. Acesso em: 11.5.2026. Citado 2 vezes nas páginas 13 e 25.

BELO, N. M.; BRASIL, H. G. Assimetria informacional e eficiência semiforte do mercado. *RAE - Revista de Administracao de Empresas*, v. 46, p. 48–57, Jan. 2006. Disponível em: <https://periodicos.fgv.br/rae/article/view/37016>. Citado na página 19.

BEZERRA, M. I. S. Apostila de análise de séries temporais. 2006. Citado na página 21.

BOLLEN, J.; MAO, H.; ZENG, X. Twitter mood predicts the stock market. *Journal of Computational Science*, v. 2, n. 1, p. 1–8, 2011. Citado na página 41.

BRACKE, P. et al. *Machine learning explainability in finance: an application to default risk analysis*. [S.l.], 2019. Disponível em: <https://www.bankofengland.co.uk/working-paper-/2019/machine-learning-explainability-in-finance-an-application-to-default-risk-analysis>. Acesso em: 11.5.2026. Citado na página 25.

BRACKE, P. et al. Performance, fairness, and explainability in ai-based credit scoring: a systematic literature review. *Journal of Risk and Financial Management*, MDPI, v. 19, n. 2, p. 104, 2025. Disponível em: <https://www.mdpi.com/1911-8074/19/2/104>. Acesso em: 11.5.2026. Citado na página 26.

Brasil. *Lei nº 13.709, de 14 de agosto de 2018. Lei Geral de Proteção de Dados Pessoais (LGPD)*. 2018. Diário Oficial da União, Brasília, DF. Disponível em: <https://www.planalto-.gov.br/ccivil_03/_ato2015-2018/2018/lei/l13709.htm>. Acesso em: 11.5.2026. Citado 2 vezes nas páginas 13 e 25.

BRASIL, B. C. do. *Política monetária*. 2025. Disponível em: <https://www.bcb.gov.br-/controleinflacao>. Acesso em: 12.7.2025. Citado na página 15.

BRIGO, D. et al. *Interpretability in deep learning for finance: a case study for the Heston model*. 2021. Disponível em: <https://arxiv.org/abs/2104.09476>. Citado na página 12.

BURTON, A. L. Ols (linear) regression. In: BARNES, J. C.; FORDE, D. R. (Ed.). *The Encyclopedia of Research Methods in Criminology and Criminal Justice*. [S.l.]: Wiley, 2021. p. 509–514. Citado na página 24.

BüCKER, M. et al. Transparency, auditability, and explainability of machine learning models in credit scoring. *Journal of the Operational Research Society*, v. 73, n. 1, p. 70–90, 2022. Citado na página 25.

CARDOSO, R. F. *Predição de volatilidade utilizando a transformada wavelet e os modelos ARIMA e GARCH*. Dissertação (Trabalho de Graduação em Engenharia de Informação) — Universidade Federal do ABC, Santo André - SP, 2024. Citado na página 23.

CARRARA, A. F.; CORREA, A. L. O regime de metas de inflação no brasil: uma análise empírica do ipca. *Rev. econ. contemp.*, 2012. Citado na página 15.

CASTELNUOVO, E.; GALIMBERTI, J. K.; SUARDI, S. Forecasting in a complex environment: machine learning sales expectations in a stock flow consistent agent-based simulation model. *Journal of Economic Dynamics and Control*, 2022. Citado 2 vezes nas páginas 29 e 64.

CHERNOZHUKOV, V. et al. Double/debiased machine learning for treatment and structural parameters. *The Econometrics Journal*, v. 21, n. 1, p. C1–C68, 2018. Citado na página 40.

CHERNOZHUKOV, V. et al. *Generic Machine Learning Inference on Heterogeneous Treatment Effects in Randomized Experiments*. [S.l.], 2018. Disponível em: <https://www-.nber.org/papers/w24678>. Citado 2 vezes nas páginas 57 e 66.

CHO, D. C.; ELTON, E. J.; GRUBER, M. J. On the robustness of the roll and ross arbitrage pricing theory. *Journal of Financial and Quantitative Analysis*, v. 19, n. 1, p. 1–10, 1984. Citado na página 18.

COELHO, C. J. *Regressão Linear Múltipla*. 2014. Slide de aula / Material didático. Fundamentos IV; Grupo de Pesquisa em Computação Científica (GPCC). Citado na página 23.

DAVIDSON, P. Rational expectations: A fallacious foundation for studying crucial decision-making processes. *Journal of Post Keynesian Economics*, Routledge, v. 5, n. 2, p. 182–198, 1982. Citado na página 17.

DIMSON, E.; MUSSAVIAN, M. A brief history of market efficiency. *Journal of Post Keynesian Economics*, v. 3, n. 3, p. 959–970, 1998. Citado na página 17.

DORNELAS, S. R. A. de S.; ARAGÓN, E. K. da S. B. Choques monetários e flutuações macroeconômicas no brasil. 2024. Citado na página 19.

FAMA, E. F. Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, v. 25, n. 2, p. 383–417, 1970. Papers and Proceedings of the Twenty-Eighth Annual Meeting of the American Finance Association New York, N.Y. December, 28-30, 1969. Citado na página 19.

FRENCH, C. W. The treynor capital asset pricing model. *Journal of Investment Management*, v. 1, n. 2, p. 60–72, 2003. Citado na página 17.

FRIEDMAN, J. H. Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, v. 29, n. 5, p. 1189–1232, 2001. Citado na página 49.

GULEN, H.; JENS, C.; PAGE, B. Balancing external vs. internal validity: An application of causal forest in finance. *SSRN Electronic Journal*, 2024. Available at SSRN: SSRN Scholarly Paper ID 3583685. Disponível em: <https://ssrn.com/abstract=3583685>. Citado na página 44.

HOANG, D.; WIEGRATZ, K. Machine learning methods in finance: Recent applications and prospects. *European Financial Management*, 2022. Disponível em: <https://doi.org/10.1111-/eufm.12408>. Citado na página 43.

INOUE, A.; JIN, L.; ROSSI, B. Rolling window selection for out-of-sample forecasting with time-varying parameters. *Journal of Econometrics*, v. 196, n. 1, p. 55–67, 2017. Citado 2 vezes nas páginas 36 e 67.

KLEIN, L. R. The is-lm model: Its role in macroeconomics. In: ____. *IS-LM and Modern Macroeconomics*. Dordrecht: Springer Netherlands, 2000. p. 151–159. ISBN 978-94-010-0644-6. Disponível em: <https://doi.org/10.1007/978-94-010-0644-6_11>. Citado na página 16.

LUBIK, T. A.; SURICO, P. The lucas critique and the stability of empirical models. *Journal of Applied Econometrics*, v. 25, n. 1, p. 177–194, 2010. Citado 2 vezes nas páginas 29 e 64.

LUCAS, R. E. Econometric policy evaluation: a critique. In: BRUNNER, K.; MELTZER, A. H. (Ed.). *The Phillips Curve and Labor Markets*. [S.l.]: North-Holland, 1976, (Carnegie-Rochester Conference Series on Public Policy, v. 1). p. 19–46. Citado 5 vezes nas páginas 24, 29, 36, 63 e 67.

LUNDBERG, S. M.; ALLEN, P. G.; LEE, S.-I. *A Unified Approach to Interpreting Model Predictions*. [S.l.], 2017. Disponível em: <https://github.com/slundberg/shap>. Citado 2 vezes nas páginas 7 e 61.

NAZEMI, A.; FABOZZI, F. J. Interpretable machine learning for creditor recovery rates. *Journal of Banking & Finance*, v. 164, p. 107187, 2024. ISSN 0378-4266. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0378426624001043>. Citado na página 12.

NEWBOLD, P. Arima model building and the time series analysis approach to forecasting. *Journal of Forecasting*, v. 2, n. 1, p. 23–35, 1983. Citado na página 23.

NIE, X.; WAGER, S. Quasi-oracle estimation of heterogeneous treatment effects. *Biometrika*, v. 108, n. 2, p. 299–319, 2021. Citado na página 40.

NUNES, R. V.; COMPAGNORE, R. N.; SALES, G. A. W. Relação entre as variáveis risco país, Índice bovespa e taxa de câmbio no mercado brasileiro. *Práticas em Contabilidade e Gestão*, v. 8, n. 2, set. 2020. Disponível em: <https://editorarevistas.mackenzie.br/index.php-/pcg/article/view/13370>. Citado na página 16.

PONTEL, J.; TRISTÃO, P. A.; BOLIGON, J. A. R. O comportamento da taxa Selic e as operações de investimento e financiamento de pessoa física no período pós-crise econômica. *Revista Gestão Organizacional*, v. 13, n. 2, 2020. Disponível em: <https:-//bell.unochapeco.edu.br/revistas/index.php/rgo/article/view/4924>. Citado na página 15.

QIU, J.; JAMMALAMADAKA, S. R.; NING, N. Multivariate time series analysis from a bayesian machine learning perspective. *Annals of Mathematics and Artificial Intelligence*, Springer, v. 88, p. 1061–1082, 2020. Disponível em: <https://doi.org/10.1007/s10472-020-09710-6>. Citado na página 43.

REHILL, P. How do applied researchers use the causal forest? a methodological review of a method. *arXiv preprint arXiv:2404.13356*, 2024. Version v2, last revised 20 Dec 2024. Citado na página 28.

RODRíGUEZ, N. D. Country risk in foreign direct investment: similarities and differences with country risk in exports. *Nómadas. Critical Journal of Social and Juridical Sciences*, v. 49, p. 83–98, sep. 2016. Disponível em: <https://revistas.ucm.es/index.php/NOMA/article/view-/53538>. Citado na página 16.

ROSENBAUM, P. R.; RUBIN, D. B. The central role of the propensity score in observational studies for causal effects. *Biometrika*, v. 70, n. 1, p. 41–55, 1983. Citado na página 41.

ROSS, S. The arbitrage pricing theory. *Journal of Economic Theory*, v. 13, n. 3, p. 341–360, 1976. Citado na página 18.

RUBIN, D. B. Estimating causal effects of treatments in randomized and nonrandomized studies. *Journal of Educational Psychology*, v. 66, n. 5, p. 688–701, 1974. Citado na página 41.

RUDEBUSCH, G. D. Assessing the lucas critique in monetary policy models. *Journal of Money, Credit and Banking*, v. 37, n. 2, p. 245–272, 2005. Citado na página 29.

RUDIN, C. *Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead*. 2019. Disponível em: <https://arxiv.org/abs/1811-.10154>. Citado na página 12.

SCHAFFER, A. L.; DOBBINS, T. A.; PEARSON, S.-A. Interrupted time series analysis using autoregressive integrated moving average (arima) models: a guide for evaluating large-scale health interventions. *BMC Medical Research Methodology*, v. 21, p. 58, 2021. Disponível em: <https://doi.org/10.1186/s12874-021-01235-8>. Citado na página 43.

SCHLITZER, G. Testing the stationarity of economic time series: further monte carlo evidence. *Ricerche Economiche*, v. 49, n. 2, p. 125–144, 1995. ISSN 0035-5054. Disponível em: <https://www.sciencedirect.com/science/article/pii/0035505495900195>. Citado na página 22.

SCOTT, S. L.; VARIAN, H. R. Predicting the present with bayesian structural time series. *International Journal of Mathematical Modelling and Numerical Optimisation*, v. 5, n. 1/2, p. 4, 2014. Citado na página 27.

SUN, C.; ZHANG, D. Assessing the financial performance of forestry-related investment vehicles: Capital asset pricing model vs. arbitrage pricing theory. *American Journal of Agricultural Economics*, v. 83, p. 617–28, 08 2001. Citado na página 18.

WAGER, S.; ATHEY, S. Estimation and inference of heterogeneous treatment effects using random forests. *Journal of the American Statistical Association*, v. 113, p. 1228–1242, 7 2018. ISSN 0162-1459. Citado na página 28.

YANG, J. et al. Climate adaptive energy efficiency modeling using a generalized additive approach to optimize building performance across chinese climate zones. *Scientific Reports*, v. 15, n. 1, 2023. Citado na página 26.

YEN, G.; LEE, C.-f. Efficient market hypothesis (emh): Past, present and future. *Review of Pacific Basin Financial Markets and Policies*, v. 11, n. 02, p. 305–329, 2008. Citado na página 19.

ZHANG, S. Impact of heterogeneous data on financial market volatility: A generalized additive model approach. *Desconhecido*, v. 1, n. 3, 2025. Disponível em: <https://doi.org/10.61173-/ykjrid172>. Citado na página 43.

ČERNEVIčIENė, J.; KABAšINSKAS, A. Explainable artificial intelligence (xai) in finance: a systematic literature review. *Artificial Intelligence Review*, v. 57, p. 216, 2024. Citado na página 25.